



GRADO EN INGENIERÍA MATEMÁTICA E INTELIGENCIA ARTIFICIAL

TRABAJO FIN DE GRADO

Interacciones y Dinámicas en la Aldea Global:
Modelado Matemático y Psicosocial de la
Guerra Cognitiva en Redes Complejas

Autor: Jorge Enebral Alonso

Director: David Martín-Corral Calvo

Madrid, Junio 2026

Declaro, bajo mi responsabilidad, que el Proyecto presentado con el título
**Interacciones y Dinámicas en la Aldea Global: Modelado Matemático y
Psicosocial de la Guerra Cognitiva en Redes Complejas**
en la ETS de Ingeniería - ICAI de la Universidad Pontificia Comillas en el
curso académico 2025/2026 es de mi autoría, original e inédito y
no ha sido presentado con anterioridad a otros efectos.

El Proyecto no es plagio de otro, ni total ni parcialmente, y la información que ha
sido tomada de otros documentos está debidamente referenciada.

Fdo.: Jorge Enebral Alonso

Fecha: 15 / 06 / 2026

Autorizada la entrega del proyecto

EL DIRECTOR DEL PROYECTO

Fdo.: David Martín-Corral Calvo

Fecha: 15 / 06 / 2026



GRADO EN INGENIERÍA MATEMÁTICA E INTELIGENCIA ARTIFICIAL

TRABAJO FIN DE GRADO

Interacciones y Dinámicas en la Aldea Global:
Modelado Matemático y Psicosocial de la
Guerra Cognitiva en Redes Complejas

Autor: Jorge Enebral Alonso

Director: David Martín-Corral Calvo

Madrid, Junio 2026

INTERACCIONES Y DINÁMICAS EN LA ALDEA GLOBAL: MODELADO MATEMÁTICO Y PSICOSOCIAL DE LA GUERRA COGNITIVA EN REDES COMPLEJAS

Autor: Jorge Enebral Alonso

Director: David Martín-Corral Calvo

Resumen

Este trabajo diseña y construye un simulador multiagente de propagación de narrativas sobre redes complejas para medir la *resistencia cognitiva* de una población frente a un ataque informativo. El simulador combina topologías libre de escala y mundo pequeño con un modelo de agente de umbral lineal, y ejecuta un barrido experimental OFAT (One Factor At a Time) de 2000 corridas con 50 réplicas Monte Carlo. Los resultados muestran que la ganancia de persuasión γ y la probabilidad de reenvío son los factores más determinantes de la vulnerabilidad, y que la red libre de escala es significativamente más vulnerable que la de mundo pequeño.

Palabras clave: guerra cognitiva; modelado basado en agentes; resiliencia cognitiva; redes complejas; propagación de narrativas; libre de escala; mundo pequeño.

Resumen ejecutivo

1 Introducción

La desinformación en redes sociales ha dejado de ser un fenómeno marginal para convertirse en un instrumento de *guerra cognitiva*: el empleo deliberado de mensajes para alterar la percepción, la creencia y la decisión de una población objetivo. La OTAN reconoce formalmente la mente humana como dominio operativo y define la superioridad cognitiva como la capacidad de percibir y actuar sobre el entorno con mayor eficacia que el adversario. La información falsa se propaga hasta seis veces más rápido que la veraz, y los ataques se amplifican mediante la estructura de las plataformas digitales, cuyas redes libre de escala concentran la influencia en un pequeño número de *hubs*.

Pese a la creciente literatura doctrinal, existe un vacío metodológico: no se dispone de un banco de pruebas abierto, cuantitativo y reproducible que permita medir cómo la *resistencia cognitiva* de una población depende de (i) la topología de la red social y (ii) los parámetros de la campaña informativa. Este trabajo cubre ese vacío.

2 Objetivos

El objetivo principal es diseñar y construir un simulador multiagente de propagación de narrativas que permita medir la resistencia cognitiva de una población ante distintas condiciones de ataque. Los objetivos secundarios son: (O1) formalizar la sociedad como grafo en sus variantes libre de escala (capa digital) y mundo pequeño (capa analógica); (O2) implementar un agente de umbral lineal con heterogeneidad cognitiva; y (O3) ejecutar un barrido experimental OFAT sobre siete factores de la campaña y cuantificar su efecto sobre la resiliencia poblacional. Este Resumen Ejecutivo describe el subconjunto llevado a simulación y análisis experimental; el marco teórico completo —que incluye el grafo de Erdős–Rényi, redes empíricas SNAP y el agente cognitivo-emocional— se desarrolla en el cuerpo de la memoria.

La pregunta central del trabajo es: *¿qué propiedades de la narrativa y de la red determinan si una población resiste o colapsa ante una campaña de desinformación?*

3 Descripción del simulador

El simulador se construye sobre **Mesa3.x** (Python) y **NetworkX**. El objeto central es el mensaje, formalizado como una tupla de doce campos que incluye veracidad percibida, carga emocional y trazabilidad causal. Cada agente ejecuta el bucle OODA: observa mensajes, actualiza su convicción c_i según la ecuación $c_i \leftarrow c_i + (1 - c_i) \cdot \tau \cdot \lambda \cdot \gamma$, y adopta la narrativa cuando $c_i \geq \theta_i$. El umbral θ_i se muestrea de una distribución bimodal que modela dos subpoblaciones: susceptibles ($\mu_s = 0,30$) y resistentes ($\mu_r = 0,70$).

El diseño experimental sigue la estrategia OFAT: se fija una configuración de referencia y se varía un único factor por experimento sobre dos topologías (libre de escala y mundo pequeño). En total se ejecutan 2000 corridas de simulación con $N = 10\,000$ agentes y 45 pasos de simulación (equivalentes a 3 días a razón de 15 pasos/día, donde cada paso representa 1 hora).

4 Resultados

5 Conclusiones



Figura 1: Arquitectura del agente resistente sobre la red social. Un nodo de la red (con cerebro) se expande para mostrar el bucle OODA: (1) **Observar** (filtrar mensajes de narrativa del inbox), (2) **Orientar** (actualizar convicción c_i y comprobar umbral θ_i) y (3) **Decidir/Actuar** (re-emitar narrativa o ruido al grafo).

INTERACTIONS AND DYNAMICS IN THE GLOBAL VILLAGE: MATHEMATICAL AND PSYCHOSOCIAL MODELLING OF COGNITIVE WARFARE IN COMPLEX NETWORKS

Author: Jorge Enebral Alonso

Director: David Martín-Corral Calvo

Abstract

This work designs and builds a multi-agent simulator of narrative propagation over complex networks to measure the *cognitive resilience* of a population against an information attack. The simulator combines scale-free and small-world topologies with a linear threshold agent model and runs an OFAT (One Factor At a Time) experimental sweep of 2000 runs with 50 Monte Carlo replicas. Results show that persuasion gain γ and forwarding probability are the strongest drivers of vulnerability, and that scale-free networks are significantly more vulnerable than small-world networks.

Keywords: cognitive warfare; agent-based modelling; cognitive resilience; complex networks; narrative propagation; scale-free; small-world.

Executive Summary

1 Introduction

Disinformation in social networks has evolved from a marginal phenomenon into an instrument of *cognitive warfare*: the deliberate use of messages to alter the perception, belief and decision-making of a target population. NATO formally recognises the human mind as an operational domain and defines cognitive superiority as the ability to perceive and act on the environment more effectively than the adversary. False information spreads up to six times faster than true information, and attacks are amplified by the structure of digital platforms, whose scale-free networks concentrate influence in a small number of high-degree *hubs*.

Despite a growing doctrinal literature, a methodological gap remains: there is no open, quantitative, reproducible testbed that enables measurement of how *cognitive resilience* depends on (i) the topology of the social network and (ii) the parameters of the information campaign. This work fills that gap.

2 Objectives

The primary objective is to design and build a multi-agent simulator of narrative propagation capable of measuring the cognitive resilience of a population under varying attack

conditions. Secondary objectives are: (O1) formalise society as a graph in its scale-free (digital layer) and small-world (analogue layer) variants; (O2) implement a linear threshold agent with cognitive heterogeneity; and (O3) execute an OFAT experimental sweep over seven campaign factors and quantify their effect on population resilience. This Executive Summary describes the subset taken to simulation and experimental analysis; the full theoretical framework — Erdős–Rényi graphs, empirical SNAP networks, and the cognitive-emotional agent — is developed in the main body of the report.

The central research question is: *which properties of the narrative and the network determine whether a population resists or collapses under a disinformation campaign?*

3 Description of the Simulator

The simulator is built on `Mesa3.x` (Python) and `NetworkX`. The central object is the message, formalised as a twelve-field tuple including perceived veracity, emotional load and causal traceability. Each agent executes the OODA loop: it observes messages, updates its conviction c_i according to $c_i \leftarrow c_i + (1 - c_i) \cdot \tau \cdot \lambda \cdot \gamma$, and adopts the narrative when $c_i \geq \theta_i$. The threshold θ_i is sampled from a bimodal distribution modelling two subpopulations: susceptible ($\mu_s = 0.30$) and resistant ($\mu_r = 0.70$).



Figure 1: Architecture of the resistant agent on the social network. One node of the network (with a brain) is expanded to show the OODA loop: **(1) Observe** (filter narrative messages from inbox), **(2) Orient** (update conviction c_i and check threshold θ_i) and **(3) Decide/Act** (re-emit narrative or noise to the graph).

The experimental design follows the OFAT strategy: a reference configuration is fixed and

a single factor is varied per experiment across two topologies (scale-free and small-world). In total, 2000 simulation runs are executed with $N = 10\,000$ agents and 45 simulation steps (equivalent to 3 days at 15 steps/day, where each step represents 1 hour).

4 Results

5 Conclusions

Índice

Índice de figuras

Índice de tablas

Capítulo 1 Introducción

La metáfora de la *aldea global* acuñada por McLuhan **McLuhan1964** anticipó una humanidad reconectada por los medios electrónicos en un único espacio de comunicación instantánea. Las redes sociales digitales han llevado esa intuición al extremo: hoy dos personas cualesquiera están separadas, en promedio, por menos de cuatro intermediarios **Backstrom2012**. Esta hiperconexión, motor de oportunidades sin precedentes, es también una superficie de ataque. La información falsa se difunde más lejos, más rápido y a más personas que la veraz **Vosoughi2018**, y la mediación algorítmica de las plataformas favorece la formación de cámaras de eco y la polarización de la opinión pública **DelVicario2016**.

En este contexto ha emergido la *guerra cognitiva* (*cognitive warfare*) como dominio operativo reconocido formalmente por la OTAN, que la define como la lucha por la *superioridad cognitiva* **NATOChiefScientist2025**. A diferencia de la guerra convencional, su terreno no es geográfico sino mental: *el mensaje es la munición y el blanco es la mente* **Hoffman2025**. El objetivo de este capítulo es introducir el problema, justificar por qué debe abordarse y describir la aportación del trabajo.

1.1. Motivación

La literatura sobre guerra cognitiva ha crecido de forma acelerada entre 2020 y 2026, pero lo ha hecho de manera marcadamente asimétrica: es abundante en lo conceptual y doctrinal, y escasa en herramientas *abiertas, cuantitativas y reproducibles* que permitan estudiar el fenómeno de forma experimental **DeppeSchaal2024**. La mayor parte de las capacidades operativas, tanto ofensivas como defensivas, permanece clasificada.

La propagación de narrativas en redes sociales no equivale al contagio simple de una enfermedad: la adopción de creencias requiere refuerzo social desde múltiples fuentes independientes —contagio complejo en el sentido de Centola y Macy **CentolaMacy2007**— y depende de un umbral individual heterogéneo cuya distribución poblacional determina si emerge o no una cascada global **Granovetter1978, Watts2002**. Este mecanismo hace del modelado basado en agentes (ABM) la herramienta natural: permite representar explícitamente la heterogeneidad individual y la estructura local de la red, capturando propiedades emergentes que los modelos de campo medio no pueden reproducir.

Existe, por tanto, un vacío metodológico: no se dispone de un banco de pruebas que permita *medir* cómo una población absorbe o resiste la propagación de una narrativa en función de (i) la topología de la red social que la sostiene y (ii) la psicología de los individuos que la componen. Cubrir ese vacío —aunque sea parcialmente, sobre un modelo simplificado pero matemáticamente fundamentado— es lo que motiva este proyecto, pues habilita el estudio sistemático de la *resiliencia cognitiva* como propiedad emergente y medible de un sistema social.

1.2. Objetivos

El objetivo principal de este Trabajo Fin de Grado es:

- **Objetivo principal.** Diseñar y construir un simulador multiagente de propagación de narrativas sobre redes complejas que permita medir la *resistencia cognitiva* de una población frente a un ataque informativo.

Para alcanzarlo se definen tres objetivos secundarios:

- **O1.** Formalizar matemáticamente la sociedad como un grafo en sus tres registros —aleatorio sintético, multicapa analógico-digital y real— y caracterizar sus propiedades estructurales.
- **O2.** Formalizar tres modelos de agente de complejidad creciente (reactivo estocástico, resistente por umbral y cognitivo-emocional) y situarlos en la literatura de difusión y contagio social.
- **O3.** Implementar un subconjunto representativo (red libre de escala con agente resistente), definir métricas de resistencia poblacional e individual, y ejecutar un barrido experimental OFAT sobre siete factores de la campaña para cuantificar su efecto sobre la resiliencia poblacional.

1.3. Estructura del trabajo

El resto de la memoria se organiza como sigue.

El Capítulo 2 (Estado del arte) revisa de forma sintética los trabajos de referencia en los tres ejes del proyecto: guerra cognitiva —del concepto de du Cluzel **DuCluzel2021** a las métricas de superioridad cognitiva de la OTAN **NATOChiefScientist2025**, **RushingHerschXu2026**—, modelado de la sociedad como red compleja —de Erdős-Rényi **ErdosRenyi1960** a las redes libre de escala **BarabasiAlbert1999** y mundo pequeño **WattsStrogatz1998**—, y dinámicas de contagio y comportamiento colectivo —modelos de umbral **Granovetter1978**, **Watts2002**, contagio complejo **CentolaMacy2007** y maximización de influencia **KempeKleinbergTard**. El capítulo cierra identificando el vacío metodológico que justifica el simulador.

El Capítulo 3 (Metodología) se divide en tres partes. El marco teórico formaliza el objeto mensaje y el bucle OODA como núcleo del ciclo de simulación, los modelos generativos de grafo y la jerarquía de agentes de complejidad creciente. La implementación describe las cinco capas de código (grafos, agentes, simulación, visualización, experimentos) y el pipeline TX/RX que garantiza reproducibilidad por semilla. La sección de simulación detalla la arquitectura del experimento: hiperparámetros fijos y barridos, diseño OFAT y las métricas de resistencia poblacional e individual.

El Capítulo ?? (Resultados) analiza el barrido OFAT ejecutado: evolución de la tasa de ataque por factor y topología, impacto de la estrategia de siembra en *hubs* frente a aleatoria,

y síntesis en un *ranking* de factores por impacto sobre la resiliencia. El Capítulo ?? (Conclusiones y Trabajo Futuro) recoge las contribuciones principales del trabajo y propone líneas de extensión futura.

Los Anexos recogen la tabla completa de resultados del barrido OFAT (tasa de ataque media y σ para todas las celdas) y el conjunto extendido de métricas estructurales de las cuatro topologías estudiadas (Erdős–Rényi, Watts–Strogatz, libre de escala, SNAP).

Capítulo 2 Estado del arte

Este capítulo sitúa el proyecto en la literatura mediante una selección breve de trabajos de referencia en los tres ejes que confluyen en él: la guerra cognitiva, el modelado de la sociedad como red compleja y las dinámicas de contagio y comportamiento colectivo. El desarrollo formal de los modelos se reserva para la metodología (Capítulo 3).

2.1. Guerra cognitiva

El documento fundacional de du Cluzel **DuCluzel2021**, elaborado para el Innovation Hub del Mando Aliado de Transformación de la OTAN, introdujo la definición hoy canónica de guerra cognitiva: el arte de emplear tecnologías para alterar la cognición de objetivos humanos, a menudo sin su conocimiento ni consentimiento. Su aportación más duradera es elevar la mente humana a la categoría de dominio operativo, más allá de los cinco dominios clásicos (tierra, mar, aire, espacio y ciberespacio).

Deppe y Schaal **DeppeSchaal2024** realizan el primer análisis conceptual académico del concepto exploratorio de guerra cognitiva del Mando Aliado de Transformación. Los autores, desde la Universidad de la Bundeswehr, examinan críticamente la coherencia interna del concepto, delimitan sus fronteras respecto a nociones vecinas (operaciones de información, operaciones psicológicas) y tienden un puente entre la investigación militar y la civil. Su revisión confirma la asimetría que motiva este trabajo: la literatura es abundante en lo conceptual y doctrinal, pero escasa en instrumentos empíricos y cuantitativos de medición.

Hoffman **Hoffman2025** ofrece una revisión exhaustiva de la literatura occidental y china sobre el fenómeno, fruto de más de cuatro décadas de experiencia en el Departamento de Defensa estadounidense. Propone una definición refinada centrada en mensajes dirigidos y métodos no violentos contra decisores —civiles o militares— o contra la población general de un Estado objetivo, sintetizada en la máxima de que *el mensaje es la munición y el blanco es la mente*.

El informe del Científico Jefe de la OTAN **NATOChiefScientist2025** constituye el marco público más riguroso publicado hasta la fecha. Define la guerra cognitiva como la lucha por la *superioridad cognitiva* y articula tres funciones operativas: *degradar* las capacidades cognitivas del adversario, *mejorar* las propias y *resistir* los ataques cognitivos. Es precisamente la tercera función, la resiliencia, la que el presente trabajo operacionaliza en forma de métricas medibles sobre una población simulada.

Rushing, Hersch y Xu **RushingHerschXu2026** proponen la primera formalización unificada de la guerra cognitiva: un marco de interacción atacante–defensor anclado en el bucle OODA (*Observe–Orient–Decide–Act*) y un conjunto de atributos medibles de superioridad cognitiva, ilustrados mediante un caso de estudio. Su contribución central para este trabajo es conceptual: tratar la cognición colectiva como un sistema observable, atacable y, por tanto, simulable. El bucle OODA de este marco es el que estructura el ciclo de emisión y recepción de mensajes del simulador (Capítulo 3).

2.2. Modelado de la sociedad como red compleja

La representación de una sociedad como grafo precede en décadas a la física de redes complejas y tiene su origen en el *Análisis de Redes Sociales* (SNA, *Social Network Analysis*). Moreno **Moreno1934** fundó la sociometría dibujando ya en 1934 *sociogramas* en los que las personas son puntos y sus relaciones, líneas; sobre esa base, las escuelas sociológicas de las décadas de 1960 a 1980 consolidaron el SNA como disciplina cuantitativa. Granovetter **Granovetter1973** aportó uno de sus resultados más influyentes, la *fuerza de los lazos débiles*: son los vínculos casuales, y no los íntimos, los que conectan comunidades densas entre sí y vehiculan la información nueva. El corpus metodológico del SNA quedó sistematizado en el manual de Wasserman y Faust **WassermanFaust1994**, que canoniza las métricas estructurales empleadas en este trabajo: centralidad, cohesión, transitividad y detección de subgrupos.

La caracterización estadística moderna de las redes complejas está sintetizada en el artículo de revisión de Albert y Barabási **AlbertBarabasi2002**. El trabajo unifica los hallazgos empíricos sobre redes reales —distribuciones de grado heterogéneas, alto agrupamiento, diámetros cortos— y los confronta con los modelos generativos disponibles, demostrando que las redes reales se apartan sistemáticamente del paradigma puramente aleatorio. De él se toma el aparato formal (distribución de grado, coeficiente de agrupamiento, longitud media de camino) con el que la metodología caracteriza los grafos del simulador.

El modelo de Erdős-Rényi **ErdosRenyi1960** es el punto de partida de la teoría de grafos aleatorios: cada par de nodos se conecta de forma independiente con probabilidad fija, lo que produce una distribución de grado de tipo Poisson y permite derivar analíticamente fenómenos como la emergencia de la componente gigante. Aunque carece de agrupamiento y de *hubs* —y es por tanto poco realista como modelo de sociedad—, su tratabilidad matemática lo convierte en el *baseline* de referencia frente al que contrastar cualquier topología más estructurada.

Watts y Strogatz **WattsStrogatz1998** introdujeron el modelo de *mundo pequeño* mediante un mecanismo de recableado aleatorio de una retícula regular: basta recablear una pequeña fracción de aristas para que el diámetro de la red colapse mientras el agrupamiento local permanece alto. Esta combinación —tríadas cerradas y caminos cortos— es exactamente la observada en las redes de relaciones cara a cara, por lo que en este trabajo dicho modelo representa la capa *analógica* de la sociedad.

Barabási y Albert **BarabasiAlbert1999** mostraron que el crecimiento de la red unido al *enganche preferencial* —los nodos nuevos tienden a conectarse a los ya populares— genera redes *libres de escala* cuya distribución de grado sigue una ley de potencias. Estas redes exhiben *hubs* que concentran gran parte de la conectividad, lo que las hace robustas frente a fallos aleatorios pero muy vulnerables frente a ataques dirigidos. Esta propiedad, característica de las plataformas digitales, fundamenta el experimento de siembra en *hubs* del Capítulo ??.

En el plano de las restricciones cognitivas, Dunbar **Dunbar1992** estableció, a partir de la correlación entre el tamaño del neocórtex y el de los grupos sociales en primates, que el ser humano puede mantener en torno a 150 relaciones estables y recíprocas. Este límite explica

por qué la red analógica presenta una distribución de grado acotada, en contraste con las colas pesadas de las plataformas digitales, donde el coste marginal de añadir un vínculo es prácticamente nulo.

En el extremo empírico de la escala digital, Backstrom y colaboradores **Backstrom2012** midieron el grafo completo de Facebook —más de 700 millones de usuarios— y obtuvieron una distancia media de 3,74 saltos entre dos personas cualesquiera, muy por debajo de los seis grados clásicos de Milgram. El resultado evidencia la compresión de distancias que las plataformas introducen en la sociedad y justifica la velocidad con que una narrativa puede alcanzar a toda una población conectada.

Finalmente, cuando las dimensiones analógica y digital coexisten (la vida real), el formalismo adecuado es el de las *redes multicapa* sistematizado por Kivelä y colaboradores **Kivela2014**. Su revisión unifica la notación del campo y demuestra que agregar las capas en un único grafo destruye información estructural y distorsiona métricas como la centralidad o la dinámica de difusión. Este marco es el que adopta el diseño multicapa analógico-digital del simulador.

2.3. Psicología individual y colectiva

La adopción de una idea o conducta no se explica solo por la estructura de la red, sino también por la psicología de la decisión individual. Granovetter **Granovetter1978** formalizó los *modelos de umbral* para el comportamiento colectivo: un individuo adopta una conducta cuando la fracción de su entorno que ya lo ha hecho supera su umbral particular. Su análisis demostró un resultado contraintuitivo: es la *heterogeneidad* de la distribución de umbrales —y no su media— la que determina si la acción colectiva se desencadena o se detiene. Este modelo es la base directa del agente resistente implementado en este trabajo.

Watts **Watts2002** trasladó los modelos de umbral a redes aleatorias y demostró que las *cascadas globales* son sucesos poco frecuentes pero de tamaño enorme cuando ocurren, delimitados por una *ventana de cascada* en el espacio de parámetros: si la red es demasiado dispersa la propagación muere por falta de conectividad, y si es demasiado densa los individuos quedan estabilizados por sus muchos vecinos. La existencia de este punto de inflexión motiva la curva dosis-respuesta del diseño experimental del Capítulo ??.

Centola y Macy **CentolaMacy2007** introdujeron la distinción entre contagio *simple* y *complejo*. En el contagio simple —propio de enfermedades o de información trivial— basta un único contacto para transmitir; en el complejo —propio de creencias, normas y conductas costosas— el individuo requiere refuerzo social desde múltiples fuentes independientes. Los autores muestran que los lazos largos, decisivos para el contagio simple, pueden ser inútiles para el complejo. Esta distinción justifica el uso de modelos de umbral, en lugar de modelos puramente epidémicos, para representar la adopción de narrativas.

Kempe, Kleinberg y Tardos **KempeKleinbergTardos2003** formularon la *maximización de la influencia* como problema algorítmico: elegir el conjunto de nodos semilla que maximiza la difusión esperada. Demostraron que el problema es NP-duro pero que, por la submodularidad de la función de influencia, un algoritmo voraz garantiza una aproximación del 63 %

del óptimo. Visto desde la óptica de la guerra cognitiva, este resultado describe formalmente la estrategia óptima del atacante, y es el contrapunto teórico del experimento de siembra dirigida en *hubs*.

Del Vicario y colaboradores **DelVicario2016** analizaron empíricamente la difusión de desinformación en Facebook comparando noticias científicas y teorías conspirativas. Encontraron que ambas se propagan dentro de *cámaras de eco* —comunidades homogéneas y polarizadas— y que la homogeneidad ideológica del vecindario, más que cualquier atributo del contenido, es el principal predictor de la difusión. El hallazgo conecta la estructura comunitaria de la red con la vulnerabilidad cognitiva de la población.

Por último, Vosoughi, Roy y Aral **Vosoughi2018** estudiaron unas 126 000 cascadas de rumores en Twitter verificadas externamente y concluyeron que la información falsa llega más lejos, más rápido y a más personas que la veraz, y que son los humanos —no los *bots*— quienes la amplifican, atraídos por su mayor novedad y por las emociones que suscita. Este resultado respalda la decisión de dotar al objeto mensaje del simulador de una dimensión emocional explícita.

2.4. Vacío identificado

Pese a la solidez de cada eje por separado, no se ha encontrado un simulador abierto que integre simultáneamente una topología social realista con confianza diferenciada por capa, un agente cognitivo dotado de umbral de adopción heterogéneo, y métricas explícitas de resistencia cognitiva. Cubrir esa intersección es la aportación metodológica de este trabajo.

Capítulo 3 Metodología

Este capítulo desarrolla, en primer lugar, el marco teórico que da soporte al simulador —el objeto *mensaje* y el bucle OODA, los modelos de grafo y los modelos de agente—; a continuación describe la implementación de los componentes programados (grafos y agentes); y finalmente detalla la simulación: la arquitectura del código, el pipeline y el diseño experimental del barrido OFAT.

3.1. Marco teórico desarrollado

3.1.1. Guerra cognitiva: del concepto al modelo operable

La guerra cognitiva no es una disciplina nueva, pero su formalización operativa como objeto de modelado computacional sí lo es. Antes de entrar en el modelo, conviene situar el concepto frente a los dos términos con los que a menudo se confunde: las *operaciones psicológicas* (PSYOPS) y las *operaciones de influencia* RushingHerschXu2026, Deppeschaal2024.

Las **PSYOPS** son acciones comunicativas planificadas y dirigidas a públicos objetivo concretos para modificar actitudes o conductas a corto plazo: históricamente vinculadas a contextos de combate, operan sobre el *contenido* de una creencia específica. Las **operaciones de influencia** son más amplias: combinan PSYOPS, medios encubiertos y gestión del entorno informativo para afectar percepciones y procesos decisorios de actores identificados. La **guerra cognitiva** eleva el nivel de ambición: su objetivo no es cambiar una creencia concreta, sino reconfigurar la *arquitectura perceptual* del adversario de forma duradera —los mecanismos mediante los que observa, interpreta y decide sobre cualquier información futura. Dicho de otro modo: las PSYOPS atacan conclusiones; las operaciones de influencia atacan el entorno informativo; la guerra cognitiva ataca el proceso de razonamiento mismo.

En este marco, el campo de batalla no es territorial sino mental: lo que se disputa es la *superioridad cognitiva*, definida por la OTAN como la capacidad de un actor para percibir, comprender y actuar sobre el entorno con mayor eficacia que sus adversarios NATOChiefScientist2025.

Objetivos, capacidades y asimetría de costes. El marco de Rushing et al. RushingHerschXu2026 estructura simétricamente los roles de atacante y defensor en cada fase del bucle OODA (Figura 1).

El **atacante** opera con alta asimetría de costes a su favor: produce y distribuye narrativas a coste marginal casi nulo aprovechando plataformas digitales e IA generativa. Sus *objetivos de efecto* son cuatro: (i) **efectos de observación** —saturar o sesgar qué información recibe el objetivo—; (ii) **efectos de orientación** —distorsionar el sensemaking mediante encuadres, cebado emocional o narrativas adversariales—; (iii) **efectos de decisión** —inducir indecisión, sobreconfianza o dependencia de atajos cognitivos—; y (iv) **efectos de acción** —provocar acciones prematuras o desalineadas. Sus *capacidades habilitadoras* son: acceso y distribución, ingeniería de contenidos y narrativas, amplificación y optimización, y adaptación continua.

El **defensor** actúa en sentido inverso: preservar la calidad de cada fase del bucle bajo presión adversarial. Sus *funciones de protección* son simétricas a los efectos del atacante: protección de la observación, protección de la orientación, protección de la decisión y protección de la acción. Sus *capacidades habilitadoras* son: detección y evaluación, resiliencia cognitiva, respuesta y mitigación, y aprendizaje adaptativo. La asimetría estructural es desfavorable al defensor: el coste marginal de verificar un mensaje es órdenes de magnitud mayor que el de producirlo, y la latencia de respuesta —verificación, contra-narrativa, moderación— supera con creces la del ataque inicial.




Figura 1: Marco OODA multi-horizonte de la guerra cognitiva **RushingHerschXu2026**. El bucle OODA central articula los efectos del atacante (izquierda) y las protecciones del defensor (derecha) en el horizonte agudo (corto plazo, minutos a días). El horizonte crónico (largo plazo, semanas a años) reconfigura los parámetros del bucle mediante efectos acumulativos sobre creencias y decisiones. La interacción iterativa atacante–defensor determina quién alcanza la superioridad cognitiva.

Trasladar esta definición a un simulador multiagente requiere fijar la unidad mínima de análisis. La respuesta que adopta este modelo es inequívoca: *el mensaje es la munición; el blanco, la mente* **Hoffman2025**. Una operación cognitiva es, en esencia, un flujo de mensajes que altera estados cognitivos; por tanto, el objeto central del modelo no es el agente sino el mensaje que circula entre agentes.

Bucle OODA y horizonte temporal. El mecanismo que gobierna la conducta de cada agente sigue el bucle *Observe–Orient–Decide–Act* (OODA) en su variante multi-horizonte

RushingHerschXu2026, que distingue dos escalas temporales con implicaciones cualitativamente distintas.

El **horizonte corto plazo** abarca minutos, horas o días: corresponde a la fase aguda de una campaña informativa, en la que la narrativa se difunde rápidamente aprovechando la viralidad de los *hubs* y el contagio emocional antes de que los mecanismos de verificación puedan activarse. En este horizonte dominan la velocidad de penetración (t_{50}), el alcance máximo y la amplitud del pico de nuevas conversiones, junto con las métricas de resultado poblacional: la **tasa de ataque** a —fracción de la población que adopta la narrativa— y la **resiliencia poblacional** $R = 1 - a$. Los ataques de corto plazo buscan crear hechos consumados: fijar una versión inicial de los eventos que resulte difícil de desalojar una vez instalada.

El **horizonte largo plazo** abarca semanas, meses o años: corresponde a la consolidación de la narrativa en las estructuras cognitivas de la población y en la arquitectura de la red. En este horizonte domina la entropía cognitiva H , que mide en qué medida la narrativa ha erosionado la diversidad de creencias de forma estructural y duradera.

El experimento de este trabajo opera exclusivamente en el **horizonte corto plazo**: la simulación corre durante 45 pasos equivalentes a tres días de actividad a 15 pasos/día, donde cada paso representa una hora. En cada paso cada agente puede procesar y emitir múltiples mensajes, capturando la actividad asíncrona característica del tráfico en redes sociales digitales. La evaluación del horizonte largo plazo —consolidación estructural de narrativas, erosión de instituciones— queda como línea de trabajo futuro.

En cada paso de simulación el agente: (i) *observa* los mensajes acumulados en su bandeja de entrada (*inbox*); (ii) *se orienta* actualizando su estado interno; (iii) *decide* si emite un mensaje nuevo o reenvía alguno de los recibidos; y (iv) *actúa* depositando el mensaje resultante en su buzón de salida (*outbox*). Para garantizar determinismo y eliminar condiciones de carrera, el simulador divide cada paso en dos sub-fases secuenciales: **TX** (todos los agentes ejecutan Decide+Act y pueblan sus *outboxes*) y **RX** (los mensajes se entregan a los *inboxes* de los destinatarios y se registran en las trazas). Esta separación asegura que ningún agente procesa en el mismo paso un mensaje que otro acaba de generar, reproduciendo la latencia real de cualquier canal de comunicación.

El mensaje como objeto central. El objeto central del modelo es el mensaje, formalizado como una tupla inmutable de doce campos:

$$m = (id, trace, t, src, tgt, \ell, M_{od}, e, \lambda, v, s, parent) \quad (3.1)$$

La Tabla 1 detalla el dominio y el papel de cada variable. La *capa* $\ell \in \{\text{analógica, digital}\}$ determina la función de confianza aplicable y la modalidad por defecto: la capa analógica corresponde a comunicación presencial (cara a cara), mientras que la digital admite cualquier modalidad. La *modalidad* $M_{od} \subseteq \{\text{texto, audio, imagen, vídeo}\}$ modula la ganancia de impacto perceptual del mensaje: el vídeo tiene el mayor potencial persuasivo, seguido de audio, imagen y texto, en coherencia con la literatura sobre persuasión multimodal. La *emoción*

dominante e se toma del conjunto de las ocho emociones primarias de Plutchik más la etiqueta neutra **Plutchik1980**; su presencia en el mensaje abre la puerta a modelar contagio emocional sin necesidad de una psicología del agente más elaborada. La *carga emocional* $\lambda \in [0, 1]$ cuantifica la intensidad de esa emoción y constituye el principal driver de persuasión del mensaje: un mensaje puede ser falso y aun así persuadir si su carga emocional es elevada. La *veracidad percibida* $v \in [0, 1]$ no modula directamente la persuasión —el modelo no asume que los agentes evalúan la verdad— sino que etiqueta el mensaje como *narrativa* (desinformación) cuando $v \leq v_{thr}$, distinguiéndolo del ruido neutro. Esta elección está respaldada por la evidencia empírica de que las noticias falsas se difunden significativamente más rápido y más lejos que las verdaderas **Vosoughi2018**. La *saliencia* $s \in [0, 1]$ captura la relevancia subjetiva que el receptor atribuye a la fuente; es el mecanismo por el que las fuentes de autoridad percibida ejercen mayor influencia. Por último, los campos *trace* y *parent* implementan la trazabilidad causal: *trace* agrupa todos los mensajes de una misma campaña y *parent* apunta al mensaje del que este es reenvío directo, permitiendo reconstruir el árbol de difusión completo para análisis *post hoc*.

Tabla 1: Variables del mensaje m (ecuación 3.1): símbolo, dominio y papel en el modelo.

Símbolo	Dominio	Papel en el modelo
id	UUID	Identificador único del mensaje
$trace$	UUID	Identificador de campaña; agrupa mensajes relacionados
t	$\mathbb{N}$	Paso de simulación en que se emite
src	V (nodo del grafo)	Agente emisor
tgt	V (nodo del grafo)	Agente receptor
ℓ	{analógica, digital}	Capa; determina función de confianza y modalidad por defecto
M_{od}	$\mathcal{P}(\{\text{texto, audio, imagen, vídeo}\})$	Modalidad/canal; modula ganancia de impacto perceptual
e	Emociones Plutchik $\cup$ {neutro}	Emoción dominante del mensaje Plutchik1980
λ	$[0, 1]$	Carga emocional; intensidad de la emoción del mensaje
v	$[0, 1]$	Veracidad percibida; etiqueta narrativa si $v \leq v_{thr}$
s	$[0, 1]$	Saliencia; relevancia subjetiva atribuida al emisor
$parent$	UUID $\cup$ {None}	Referencia al mensaje origen (trazabilidad causal)

La dinámica emergente del modelo nace de la coexistencia de dos *especies* de mensajes con propiedades opuestas. La *narrativa* se caracteriza por veracidad percibida baja ($v \leq v_{thr}$)

y carga emocional alta ($\lambda \approx 1$): es el vector de desinformación que persuade precisamente porque apela a la emoción y no a la evidencia. El *ruido neutro*, en cambio, presenta veracidad alta y emoción neutra: no persuade, pero mantiene activo el canal de comunicación y proporciona el ruido de fondo sobre el que la narrativa compite. Su competencia sobre la misma red genera patrones de difusión no lineales que la simulación permite observar y medir. La métrica que captura el efecto agregado es la *entropía cognitiva* definida en el marco del *Cognitive Net Assessment PolytechniqueCNA2026*: una población con creencias distribuidas de forma más uniforme —mayor entropía— es más vulnerable a la narrativa, porque ninguna creencia dominante actúa como ancla colectiva. Esta métrica operacionalizará el concepto de superioridad cognitiva en la fase de análisis de resultados, cerrando el ciclo entre el marco teórico y el diseño computacional del simulador.

3.1.2. Grafos: la sociedad como red

Una red social puede representarse formalmente como un grafo $G = (V, E)$, donde el conjunto de nodos V corresponde a los individuos que participan en el sistema y el conjunto de aristas $E \subseteq V \times V$ representa los vínculos entre ellos. La orientación del grafo depende de la capa que se modele: los vínculos presenciales son típicamente *no dirigidos* (relaciones simétricas de conocimiento mutuo), mientras que los digitales son *dirigidos* (el seguimiento en redes sociales es asimétrico por naturaleza). Ambas variantes pueden ser *ponderadas* —cuando se asigna a cada arista un valor numérico que refleja la intensidad o confianza del vínculo— y cualquiera de estas topologías puede aparecer como capa dentro de una red *multicapa*, en la que distintos tipos de relación coexisten sobre el mismo conjunto de individuos. Esta representación unificada permite aplicar al estudio de la influencia social el aparato matemático de la teoría de grafos y la ciencia de redes **AlbertBarabasi2002**.

Métricas estructurales. La caracterización cuantitativa de una red requiere un conjunto de métricas estructurales que capturan las propiedades de la topología relevantes para la dinámica de propagación. El *grado* k_i de un nodo i es el número de aristas que lo inciden; en redes dirigidas se distinguen grado de entrada k_i^{in} y grado de salida k_i^{out} . La *distribución de grado* $P(k)$ describe la fracción de nodos con grado k : constituye la huella estructural más característica de cada modelo de red y determina la heterogeneidad del sistema, la presencia de hubs y la vulnerabilidad ante intervenciones dirigidas. El *coeficiente de clustering* C_i mide la densidad de triángulos en el vecindario de i y cuantifica en qué medida los contactos de un nodo también se conocen entre sí; un clustering elevado indica una estructura comunitaria que favorece el refuerzo local de creencias. La *longitud media de camino* $\langle \ell \rangle$ refleja la eficiencia global de la propagación: redes con $\langle \ell \rangle$ pequeña permiten que una narrativa alcance nodos distantes en muy pocos saltos. Las *centralidades* de intermediación, de vector propio y PageRank cuantifican, respectivamente, el control del flujo de información entre comunidades, la influencia transitiva acumulada y la notoriedad de cada nodo en función de la relevancia de quienes apuntan a él. La *asortatividad* indica si los nodos de grado elevado tienden a conectarse entre sí o con nodos periféricos, lo que afecta tanto a la velocidad de

contagio como a la robustez de la red ante la eliminación de nodos clave.

Cuando la distribución de grado sigue una *ley de potencias*, se cumple

$$P(k) \propto k^{-\gamma}, \quad (3.2)$$

donde el exponente γ se estima mediante el estimador de máxima verosimilitud de Clauset, Shalizi y Newman **Clauset2009**:

$$\hat{\gamma} = 1 + n \left[\sum_{i=1}^n \ln \left(\frac{k_i}{k_{\min} - \frac{1}{2}} \right) \right]^{-1},$$

con $k_{\min}$ el grado mínimo a partir del cual se ajusta la ley y n el número de nodos con $k_i \geq k_{\min}$.

Topologías estudiadas. Se estudian tres modelos de red canónicos que sirven de marco de referencia para el análisis de la propagación de narrativas.

El modelo de *Erdős-Rényi* $\mathcal{G}(n, p)$ **ErdosRenyi1960** construye el grafo conectando cada par de nodos de forma independiente con probabilidad p . El grado de cada nodo sigue una distribución de Poisson con media $\langle k \rangle = (n - 1)p$. Esta topología se emplea como *baseline* aleatorio: carece de hubs, presenta clustering bajo y no reproduce las heterogeneidades observadas en redes humanas reales; en consecuencia, subestima sistemáticamente el alcance de una campaña informativa.

El modelo *libre de escala* **BarabasiAlbert1999**, **AlbertBarabasi2002** se basa en el mecanismo de adjunción preferencial: los nodos nuevos se enlazan con mayor probabilidad a nodos ya bien conectados, lo que genera la distribución de grado (3.2). El valor del exponente γ determina el régimen cualitativo de la red y tiene consecuencias directas sobre la dinámica de propagación:

- $\gamma < 2$: el grado medio diverge con el tamaño n ; la red queda dominada por uno o muy pocos super-hubs que absorben casi toda la conectividad. La propagación es extremadamente rápida, pero la red es frágil: la eliminación de esos nodos centrales la desintegra.
- $\gamma > 3$: los hubs apenas se distinguen del nodo promedio y la distribución converge a un comportamiento próximo al de Erdős-Rényi. La ley de potencias existe formalmente, pero sin consecuencias dinámicas apreciables sobre la velocidad de contagio.
- $2 < \gamma < 3$ (rango empírico): el grado medio es finito, pero la varianza diverge. Coexisten hubs con $k \gg \langle k \rangle$ y una mayoría de nodos con conectividad modesta. Las redes sociales digitales se sitúan en este intervalo —Twitter y Facebook presentan $\gamma \approx 2,1$ – $2,5$ —, que combina el efecto de mundo pequeño inducido por los hubs con una robustez moderada ante fallos aleatorios.

La generalización dirigida de Bollobás et al. **Bollobas2003** extiende el modelo al caso asimétrico, produciendo distribuciones de grado de entrada y de salida independientes, lo que la convierte en la variante más adecuada para modelar plataformas digitales donde seguir a alguien no implica reciprocidad. La distancia media entre usuarios en Facebook se aproxima a 3,5 saltos **Backstrom2012**, confirmando el efecto de mundo pequeño inducido por los hubs incluso a escala de miles de millones de nodos. En cambio, en la red libre de escala de la simulación — $n = 10\,000$ nodos, elegida para homologar la comparativa entre topologías— la baja densidad resultante ($\bar{k}_{in} = 1,87$) eleva el camino medio a $\ell = 4,32$, el más largo de las topologías sintéticas; el efecto de mundo pequeño emerge progresivamente al crecer n y no es apreciable en instancias de pequeño tamaño.

El modelo de *Watts–Strogatz* **WattsStrogatz1998** parte de un anillo regular donde cada nodo está conectado a sus k vecinos más próximos y, posteriormente, recablea cada arista con probabilidad p . Para valores intermedios de p se obtiene simultáneamente un coeficiente de clustering elevado (herencia de la estructura regular) y caminos medios cortos proporcionales a $\log n$ (consecuencia del recableado aleatorio). Esta combinación de alta cohesión local y accesibilidad global caracteriza a las redes de relaciones presenciales y la convierte en el modelo natural para la *capa analógica*.

La tabla 2 resume las diferencias estructurales más relevantes entre la red analógica y la digital.

Confianza por capa. La confianza entre dos agentes no es homogénea ni estática: depende de la capa de red en la que se establece el vínculo, y los datos empíricos imponen requerimientos cualitativamente distintos para cada una.

En la *capa analógica*, las relaciones presenciales presentan una estructura jerárquica bien documentada: los individuos organizan sus contactos en círculos de proximidad social con tamaños y frecuencias de interacción característicos. El modelo de Dunbar **Dunbar1992** identifica cuatro bandas concéntricas —núcleo íntimo (≤ 5 personas), círculo cercano (≤ 15), amigos (≤ 50) y conocidos (≤ 150)— en las que la intensidad y frecuencia del contacto decrecen progresivamente con la distancia social $d(u, v)$. La confianza en esta capa se asigna en función de la banda a la que pertenece la distancia entre dos nodos: los vínculos del núcleo íntimo reciben el valor máximo, mientras que los meros conocidos reciben el mínimo. Esta graduación reproduce la estructura jerárquica observada empíricamente en las redes de relación humana presencial.

En la *capa digital*, las relaciones de seguimiento son asimétricas y se establecen sin coste, lo que invalida la jerarquía de Dunbar. Los datos empíricos evidencian dos efectos diferenciados: (i) los nodos con muchos seguidores generan una confianza por contacto decreciente —la credibilidad percibida se diluye a medida que el alcance del emisor crece, efecto denominado de *saturación*—; (ii) compartir vecinos comunes entre emisor y receptor introduce un bono de credibilidad basado en el principio de cierre triádico. Capturando ambos efectos, la confianza en la capa digital se modela mediante una distribución log-normal cuya media y varianza dependen de las propiedades estructurales del par emisor-receptor:

Tabla 2: Comparativa estructural entre la red analógica (Watts–Strogatz) y la red digital (libre de escala).

Dimensión	Red analógica	Red digital
Modelo de base	Watts–Strogatz	Barabási–Albert dirigido Bollobas2003
Orientación	No dirigida (simétrica)	Dirigida (asimétrica)
Tamaño de la vecindad	Limitado (bandas de Dunbar Dunbar1992)	Ilimitado; hubs con $k \gg \langle k \rangle$
Coste de vínculo	Alto (tiempo, proximidad física)	Bajo (un clic, coste casi nulo)
Distribución de grado	Acotada, pico estrecho	Ley de potencias, $\gamma \in [2, 3]$ (3.2)
Distancia media $\langle \ell \rangle$	$\mathcal{O}(\log n)$, relativamente larga	Corta a gran escala ($\approx 3,5$ saltos en Facebook Backstrom2012); en la simulación ($n=10\,000$), $\ell=4,32$ por baja densidad (véase Tabla ??)
Coefficiente de clustering	Alto (estructura comunitaria)	Bajo (hubs con vecindarios dispersos)
Mediación algorítmica	Ninguna	Presente (recomendaciones, <i>trending</i>)
Confianza por arista	Según bandas de Dunbar	Log-normal modulada por grado (3.3)

$$\tau_{a \rightarrow b}^{\text{dig}} = \text{clip}(\mathcal{N}(\mu, \sigma) + 0,04 \cdot \text{mín}(c_{ab}, 5), 0, 1), \quad (3.3)$$

donde $\mu = 1/(1 + 0,005 \cdot k_b^{\text{in}})$, $\sigma = 0,05 + 0,003 \cdot k_a^{\text{out}}$, k_b^{in} es el in-grado del receptor b , k_a^{out} el out-grado del emisor a , y c_{ab} el número de vecinos comunes entre a y b .

Redes multicapa. Cuando se desea modelar simultáneamente las interacciones analógicas y digitales de una misma población, el formalismo de redes multicapa **Kivela2014**, **DeDomenico2013** proporciona el marco apropiado. Una red multicapa se define formalmente como la tupla $\mathcal{M} = (V_{\mathcal{M}}, E_{\mathcal{M}}, V, L)$, donde $L = \{L_1, \dots, L_d\}$ es el conjunto de capas, $V_{\mathcal{M}} \subseteq V \times L$ el conjunto de nodos-capa y $E_{\mathcal{M}}$ incluye tanto aristas *intra-cap*a (dentro de una misma capa) como aristas *inter-cap*a (entre capas).

En este modelo se consideran dos capas sobre el mismo conjunto de nodos V : la *capa digital* (libre de escala, dirigida) y la *capa analógica* (Watts–Strogatz, no dirigida). Los nodos representan únicamente ciudadanos reales; la capa digital no incluye bots ni actores sintéticos. Cada nodo es el mismo individuo en ambas capas, con roles complementarios según el canal de comunicación:

- **Flujo digital → analógico:** un agente recibe contenido en la capa digital —por ejemplo, un vídeo viral o una noticia de un hub—, lo procesa internamente y, si decide compartirlo, lo transmite a sus contactos de confianza en la capa analógica. La intensidad de ese reenvío es proporcional a la confianza que le merece cada contacto presencial: comparte más con quienes mantiene vínculos más fuertes.
- **Flujo analógico → digital:** un agente puede recibir información de su entorno presencial —un rumor transmitido cara a cara— y amplificarla publicándola en la capa digital, donde puede alcanzar audiencias mucho mayores gracias a la estructura de hubs.

Esta dualidad permite modelar el ciclo completo de una operación informativa: la narrativa se inyecta en la capa digital (alta velocidad, alto alcance), atraviesa la frontera inter-capas a través de los agentes más activos y se consolida en la capa analógica (alta confianza, mayor persistencia cognitiva), desde donde puede volver a amplificarse digitalmente en sucesivas iteraciones.

Redes reales (SNAP). Además de las topologías sintéticas, se incorporan redes empíricas del repositorio SNAP LeskovecKrevl2014. Los conjuntos de datos utilizados —redes de ego de Facebook y Twitter, y la red de confianza de Epinions— exhiben los sesgos estructurales característicos de las redes humanas: distribución de grado de cola pesada, alto clustering local y efecto de mundo pequeño. Cuando el grafo original es no dirigido, la orientación de las aristas se asigna de forma probabilística ponderada por el grado de los nodos extremos, aproximando la asimetría típica de las relaciones de influencia en entornos digitales.

3.1.3. Agentes: modelos psicológicos

¿Por qué modelos basados en agentes? El modelado basado en agentes (ABM, *Agent-Based Modeling*) ofrece ventajas estructurales frente a los enfoques alternativos para simular la propagación de narrativas en redes sociales.

Los modelos de ecuaciones diferenciales ordinarias (ODE), heredados de la epidemiología (modelos SIR, SIS), trabajan con densidades poblacionales homogéneas y asumen que todos los individuos son equivalentes y están en contacto potencial con todos los demás. Esta hipótesis de mezcla homogénea es fundamentalmente incorrecta para redes sociales, donde la estructura de la red —hubs, comunidades, puentes débiles— es precisamente el mecanismo que gobierna la difusión Watts2002, CentolaMacy2007. Los ABM no imponen dicha homogeneidad: la heterogeneidad emerge de la interacción local entre agentes sobre una topología específica.

Los modelos estadísticos y de aprendizaje automático son potentes para predecir patrones observados, pero no son causales: describen correlaciones entre variables pasadas sin modelar el mecanismo generador. Para el objetivo de este trabajo —medir cómo la topología y la psicología individual determinan la resiliencia cognitiva— se requiere un modelo *generativo* que permita intervenir en parámetros individuales y observar el efecto sobre la dinámica colectiva.

Los juegos evolutivos y los modelos de dinámica de opinión (DeGroot, Hegselmann-Krause) capturan la actualización de creencias pero típicamente asumen homogeneidad de la red, ausencia de contenido emocional en los mensajes, o reglas de actualización simétricas incompatibles con la dirección asimétrica de las plataformas digitales.

El ABM resuelve estas limitaciones con tres propiedades: (i) permite asignar a cada agente un umbral θ_i individual muestreado de una distribución heterogénea, condición necesaria para observar cascadas no lineales **Granovetter1978**; (ii) sitúa a cada agente en un nodo del grafo y hace que la difusión dependa explícitamente de la estructura de vecindad; y (iii) permite registrar trazas causales de cada mensaje, requisito imprescindible para el análisis *post hoc* de la dinámica de resistencia.

Se estudian tres modelos de agente de complejidad psicológica creciente, diseñados con una lógica de control experimental: el modelo más simple actúa como línea base estadística, el modelo intermedio concentra la potencia explicativa de los experimentos y el modelo más rico aporta la mayor fidelidad cognitiva, permitiendo observar los efectos de las emociones y la cognición situacional sobre la propagación de narrativas.

Agente estocástico (control nulo). El agente estocástico es un agente *reactivo puro*: carece de estado cognitivo interno y no mantiene ninguna representación de las narrativas que circulan por la red. Su comportamiento en cada paso se reduce a dos acciones independientes parametrizadas por sendas probabilidades: con probabilidad p_{fwd} reenvía el último mensaje recibido a un subconjunto aleatorio de sus vecinos en el grafo, y con probabilidad p_{fire} genera un mensaje de ruido neutro y lo emite igualmente a un subconjunto aleatorio. Ambas acciones son independientes en cada paso, de modo que un agente puede reenviar y generar ruido simultáneamente, solo una de las dos, o ninguna.

La utilidad de este modelo no es descriptiva sino metodológica. Al eliminar toda psicología individual, aísla la contribución de la *topología de la red* y del *azar* en la difusión de contenidos. Cualquier diferencia observada entre las métricas de este agente y las de los modelos más ricos debe atribuirse, por diferencia, a los mecanismos cognitivos añadidos en estos últimos. Sin este control nulo sería imposible separar el efecto estructural del grafo del efecto de los procesos individuales de resistencia o persuasión.

Agente resistente (umbral lineal cognitivo). El agente resistente incorpora un estado interno compuesto por dos escalares: la *convicción* $c_i \in [0, 1]$, que cuantifica en qué medida el agente i ha interiorizado una narrativa concreta, y el *umbral de resistencia* $\theta_i \in [0, 1]$, que marca el nivel de convicción necesario para que el agente adopte dicha narrativa.

Un mensaje pertenece a la narrativa rastreada si y solo si su veracidad v satisface $v \leq v_{\text{thr}}$, donde v_{thr} es un umbral de veracidad global configurable. Cuando el agente i recibe un mensaje de la narrativa procedente del agente j , actualiza su convicción según la regla:

$$c_i \leftarrow c_i + (1 - c_i) \cdot \tau_{j \rightarrow i} \cdot \lambda_m \cdot \gamma, \quad (3.4)$$

donde $\tau_{j \rightarrow i}$ es la confianza que el agente i deposita en el emisor j en la capa del mensaje, $\lambda_m \in [0, 1]$ es la *carga emocional* del mensaje y $\gamma > 0$ es la ganancia de persuasión por exposición. La forma multiplicativa de la ecuación garantiza que c_i permanezca acotada en $[0, 1]$ y que la tasa de incremento decrezca conforme la convicción se aproxima a la saturación, en línea con el marco del modelo de umbral lineal de **KempeKleinbergTardos2003**. El agente adopta la narrativa en el instante en que $c_i \geq \theta_i$.

Los umbrales $\{\theta_i\}$ se muestrean de una *distribución bimodal* que modela dos subpoblaciones diferenciadas. La elección de esta distribución responde a la estructura de opinión observada en poblaciones reales ante narrativas externas: la susceptibilidad ante la desinformación no se distribuye de forma continua y unimodal, sino que la población tiende a polarizarse en dos grupos. Un subgrupo de alta susceptibilidad concentra sus umbrales en valores bajos ($\theta \ll 0,5$); el subgrupo resistente sitúa los suyos en valores altos ($\theta \gg 0,5$). Esta bimodalidad, frente a cualquier distribución unimodal, es la condición mínima para reproducir los efectos de *tipping point* no lineales que caracterizan a las cascadas de desinformación reales **Granovetter1978**: con una distribución unimodal, la dinámica converge monótonamente hacia el equilibrio una vez fijada la fracción inicial de adoptantes, sin posibilidad de cascadas súbitas. Con la distribución bimodal, en cambio, la fracción de la subpoblación susceptible determina un umbral crítico de densidad: por encima de él, la campaña alcanza masivamente a la subpoblación resistente; por debajo, se extingue. La heterogeneidad de los umbrales $\{\theta_i\}$ —no su valor medio— es el factor determinante en la formación de cascadas de adopción: una distribución concentrada impide o universaliza la propagación, mientras que la bimodalidad introduce puntos de inflexión no lineales en la dinámica de difusión **Granovetter1978, Watts2002**.

El proceso de contagio generado por este modelo es de tipo *complejo*: la adopción requiere exposición reiterada al mismo contenido, en contraste con los modelos de contagio simple donde una única exposición basta. Esta propiedad lo hace cualitativamente más sensible a la estructura de los puentes débiles **CentolaMacy2007**. Una vez adoptada la narrativa, el agente no se vuelve pasivo: en cada paso ulterior re-emite espontáneamente su última narrativa con probabilidad f y emite ruido neutro con probabilidad p_{fire} , generando un *contagio autosostenido* en el que los nodos adoptados actúan como fuentes secundarias que amplifican la cascada más allá de la fuente original.

Agente cognitivo-emocional (bayesiano). El agente cognitivo-emocional es el modelo de mayor complejidad psicológica. Ejecuta el bucle *OODA* (observar, orientar, decidir, actuar) **RushingHerschXu2026**, con una fase de orientación mediada por un *cerebro emocional* vectorial que representa el estado afectivo del individuo (Figura 3).

El estado interno es un vector $\mathbf{e} \in [0, 1]^{11}$ formado por dos bloques: las ocho emociones primarias de Plutchik **Plutchik1980** (Figura 2) y tres dimensiones metacognitivas. Cada agente posee además un vector de *genética* $\mathbf{g} \in [0, 1]^{11}$ que actúa como amplificador estable e individual de la respuesta emocional, modelando la variabilidad interindividual en sensibilidad afectiva.

Emociones primarias. Las ocho emociones de Plutchik actúan como moduladores dife-

renciales de la respuesta al mensaje. La **alegría** potencia el reenvío de contenido positivo y rebaja la resistencia ante información congruente con el estado afectivo. La **confianza** amplifica la credibilidad percibida del emisor, multiplicando el impacto de los mensajes procedentes de fuentes valoradas. El **miedo** activa un estado de alerta que eleva la atención disponible pero sesga la interpretación hacia amenazas, haciendo al agente especialmente sensible a narrativas de riesgo. La **sorpresa** abre transitoriamente la ventana de atención, creando un intervalo de máxima receptividad ante la primera exposición a un contenido inesperado. La **tristeza** reduce la motivación de respuesta activa pero mantiene la receptividad pasiva. La **aversión** activa el rechazo hacia fuentes o contenidos específicos, funcionando como escudo natural ante ciertos tipos de narrativa. La **ira** posee el mayor potencial viral: activa la tendencia a compartir contenido indignante, convirtiendo al agente en amplificador involuntario de narrativas que le generan rechazo moral. La **anticipación** crea una predisposición a buscar confirmación de expectativas previas, incrementando la susceptibilidad ante contenidos que validen el marco interpretativo ya activo.




Figura 2: Rueda de emociones de Plutchik **Plutchik1980**. Las ocho emociones básicas de la periferia —alegría, confianza, miedo, sorpresa, tristeza, aversión, ira y anticipación— constituyen las primeras ocho dimensiones del vector de estado $\mathbf{e}$ del cerebro emocional. Los tonos cálidos corresponden a emociones de valencia positiva y los fríos a emociones de valencia negativa.

Dimensiones metacognitivas. Las tres dimensiones metacognitivas regulan el proceso de procesamiento en sí, no el contenido afectivo. La **atención** $\text{attn} \in [0, 1]$ cuantifica la fracción de capacidad cognitiva disponible en cada paso; no es un parámetro fijo sino una variable

dinámica que varía en función de los estímulos recibidos: crece cuando el agente recibe pocos mensajes de alta relevancia y decae bajo saturación informativa, modelando el efecto de *sobrecarga cognitiva* documentado en entornos de alta exposición mediática. La **credulidad** $cred \in [0, 1]$ es la propensión disposicional a aceptar contenidos sin verificación; relativamente estable a corto plazo, refleja rasgos cognitivos y formativos del individuo. La **autoconfianza** $self_conf \in [0, 1]$ representa la resistencia a revisar creencias propias: un agente con autoconfianza alta requiere mayor acumulación de evidencia contraria para actualizar su estado; uno con autoconfianza baja es más susceptible a la revisión por influencia externa.




Figura 3: Arquitectura del cerebro emocional vectorial del agente cognitivo-emocional. Las ocho emociones de Plutchik y las tres dimensiones metacognitivas (atención, credulidad, autoconfianza) en el centro.

Al observar un mensaje, el cerebro actualiza su estado emocional siguiendo el principio de codificación predictiva y actualización bayesiana de creencias **Friston2010**:

$$\Delta_k = m_{vec,k} \cdot g_{mod} \cdot attn \cdot \tau \cdot cred \cdot circ(h), \quad e_k \leftarrow \text{clip}(e_k + g_k \Delta_k, 0, 1), \quad k = 1, \dots, 8 \quad (3.5)$$

donde $m_{vec,k}$ es la componente k -ésima del vector emocional del mensaje, g_{mod} el factor de ganancia por modalidad (texto, imagen o vídeo), τ la confianza en el emisor y $circ(h)$

el modulador circadiano. El amplificador genético $g_k \in [0, 1]$ actúa en la actualización del estado, no en el cálculo del incremento Δ_k : amplifica o atenúa la respuesta de cada dimensión emocional de forma diferencial según la sensibilidad individual heredada; se aplica únicamente sobre las ocho emociones primarias ($k = 1, \dots, 8$), no sobre las dimensiones metacognitivas.

Decaimiento emocional y vida media. Entre pasos de simulación se aplica un decaimiento exponencial autónomo por dimensión:

$$e_k \leftarrow e_k \cdot 2^{-1/h_{1/2}},$$

donde $h_{1/2}$ es la *vida media emocional*, expresada en pasos de simulación. Dado que cada paso representa una hora de actividad, una vida media de $h_{1/2} = 3$ pasos significa que una emoción a plena intensidad se reduce a la mitad en tres horas. Con $h_{1/2} = 15$ pasos (una jornada completa), el agente conserva el 50 % de su carga afectiva al final del día; con $h_{1/2} = 3$, las emociones decaen casi por completo antes de la jornada siguiente. Esta parametrización permite calibrar desde estados afectivos efímeros —impactos mediáticos de corta duración— hasta respuestas emocionales persistentes asociadas a eventos de alta carga simbólica.

Modulador circadiano. El modulador $\text{circ}(h)$ captura la variación rítmica de la sugestionabilidad a lo largo de la jornada activa, en consonancia con los patrones afectivos observados en redes sociales **GolderMacy2011**. El modelo considera una ventana de actividad de 15 horas, de las 8:00 a las 23:00, que coincide con la ventana de uso típica de un usuario en plataformas digitales. En este intervalo, el modulador sigue un coseno con período de 12 horas:

$$\text{circ}(h) = 0,75 + 0,25 \cdot \cos\left(\frac{2\pi(h - 8)}{12}\right), \quad (3.6)$$

donde $h \in [8, 23]$ es la hora del día. La Figura ?? muestra la evolución del modulador a lo largo de la jornada.

Con un período de 12 horas, la función coseno completa 1,25 ciclos dentro de la ventana activa. El primer pico de *máxima sugestionabilidad* se sitúa a las 8:00 ($\text{circ} = 1,0$): al inicio de la jornada los mecanismos de evaluación crítica aún no han alcanzado su plena activación tras el despertar, lo que eleva la receptividad ante mensajes externos **GolderMacy2011**. El mínimo de sugestionabilidad se alcanza a las 14:00 ($\text{circ} = 0,50$), en la franja de máxima alerta cognitiva del mediodía cuando la activación atencional acumulada refuerza los mecanismos de evaluación crítica y reduce la apertura perceptual ante estímulos externos. Un segundo pico emerge a las 20:00 ($\text{circ} = 1,0$), asociado al descenso de la guardia cognitiva propio del período vespertino tardío, cuando la fatiga acumulada durante la jornada relaja los filtros de evaluación crítica. El valor base 0,75 asegura que incluso en el mínimo de las 14:00 el agente mantiene capacidad de procesamiento activa; la amplitud 0,25 refleja la magnitud del efecto circadiano sobre la sugestionabilidad, coherente con la literatura que estima la variación diurna entre un 20 % y un 30 % **GolderMacy2011**.




Figura 4: Modulador circadiano $\text{circ}(h)$ a lo largo de la jornada activa (8:00–23:00). Picos de máxima sugestionabilidad ($\text{circ} = 1,0$) a las 8:00 y 20:00; mínimo ($\text{circ} = 0,50$) a las 14:00. Base = 0,75, amplitud = 0,25, período coseno de 12 horas (ecuación (??)).

Tabla 3: Comparativa de los tres modelos de agente de complejidad psicológica creciente.

Modelo	Estado interno	Regla de decisión
Estocástico	Ninguno	Reenvío y ruido con probabilidades p_{fwd} , p_{fire}
Resistente	$c_i, \theta_i \in [0, 1]$	Umbral lineal: adoptar si $c_i \geq \theta_i$ KempeKleinbergTardos2003, Granovetter1978
Cognitivo-emocional	$\mathbf{e}, \mathbf{g} \in [0, 1]^{11}$	Actualización bayesiana del vector emocional Friston2010, Plutchik1980

3.2. Implementación

Esta sección describe los componentes efectivamente programados: la jerarquía de grafos y la de agentes, con sus parámetros de configuración y las topologías generadas. El diseño sigue el patrón de *herencia + template method*: una clase base abstracta define la interfaz y el pipeline de construcción, y cada subclase concreta implementa únicamente la topología o la psicología específica.

3.2.1. Grafos: jerarquía de implementación

La librería seleccionada para la representación y manipulación de grafos es **NetworkX NetworkX2008**. Frente a alternativas como *igraph* (núcleo en C, API Python/R) o *graph-tool* (C++ con bindings Python de instalación compleja), NetworkX es una librería puramente Python que se integra directamente con el resto del ecosistema del proyecto sin dependencias nativas adicionales. Implementa de serie todos los modelos generativos necesarios —Erdős–Rényi,

Watts–Strogatz, Barabási–Albert extendido— y expone los grafos como objetos Python inspeccionables sin conversión, lo que simplifica tanto el análisis interactivo como la recogida de trazas. Su rendimiento es suficiente para los tamaños experimentales del TFG ($n \leq 20\,000$ nodos).

El módulo `src/graphs/` organiza todas las topologías bajo una clase base abstracta `BaseGraph`. Esta clase encapsula dos responsabilidades transversales: (i) la construcción *lazy* del grafo (se construye la primera vez que se accede a `.graph`, no en el `__init__`) y (ii) la anotación automática de aristas con atributos `layer` y `trust` mediante el método `_annotate()`, que convierte cualquier topología en un `nx.MultiDiGraph` dirigido. Las subclases solo implementan `_build_topology()`, que devuelve la topología desnuda. Los parámetros comunes a toda clase son `seed` (semilla para reproducibilidad) y `layer` (`^analog` o `digital`).

Erdős–Rényi (`ErdosRenyiGraph`). Implementa el modelo $\mathcal{G}(n, p)$ **ErdosRenyi1960** mediante `networkx.erdos_renyi_graph`. Parámetros específicos: `num_nodes` (n), `edge_prob` ($p \in [0, 1]$) y `connected` (booleano: si `True`, une componentes conexas añadiendo aristas mínimas). Es el modelo de referencia aleatorio sin estructura: todos los nodos tienen probabilidad idéntica de conectarse y la distribución de grado converge a una Poisson sin hubs.




Figura 5: Erdős–Rényi $\mathcal{G}(500, 0,02)$. Sin estructura ni hubs; conectividad homogénea.

Watts–Strogatz (`WattsStrogatzGraph`). Implementa el modelo de mundo pequeño **WattsStrogatz1993** mediante `networkx.watts_strogatz_graph`. Parámetros específicos: `num_nodes`, `k` (cada nodo conectado a sus k vecinos más cercanos en el anillo inicial) y `rewire_prob` ($p_{\text{rewire}} \in [0, 1]$, fracción de aristas recableadas aleatoriamente). El parámetro `directed` controla si la topología se convierte a digrafo; si es `False`, la clase base añade ambas direcciones con igual confianza, modelando relaciones simétricas de la capa analógica. El resultado combina alto agrupamiento local (vecinos del vecino también son vecinos) con diámetro reducido por los atajos aleatorios, reproduciendo el número de Dunbar **Dunbar1992** de la capa social presencial.



Figura 6: Watts–Strogatz $n = 500$, $k = 6$, $p = 0,10$. Estructura de anillo con atajos aleatorios; grado concentrado en torno a $k = 6$ sin hubs.

Libre de escala (`ScaleFreeGraph`). Implementa la variante dirigida de Bollobás et al. **Bollobas2003** mediante `networkx.scale_free_graph`, que añade nodos siguiendo tres pasos mutuamente excluyentes con probabilidades `alpha` (α , añadir arista desde nodo nuevo), `beta` (β , arista entre nodos existentes) y `gamma` (γ_{BA} , arista hacia nodo nuevo), con la restricción $\alpha + \beta + \gamma = 1$. Los parámetros `delta_in` y `delta_out` son sesgos de preferencia de entrada y salida que modulan el exponente de la ley de potencias. Los valores de referencia ($\alpha = 0,41$, $\beta = 0,54$, $\gamma = 0,05$, $\delta_{\text{in}} = 0,2$) producen distribuciones de grado con exponente $\hat{\gamma} \in [2, 3]$, típico de

plataformas digitales **AlbertBarabasi2002**.



Figura 7: Libre de escala $n = 500$, $\alpha = 0,41$, $\beta = 0,54$, $\gamma = 0,05$. Los hubs concentran la mayoría de las aristas; grado de entrada máximo: 193 frente a 19 en Erdős–Rényi del mismo tamaño.

Red real SNAP (SNAPGraph). Carga grafos empíricos del repositorio SNAP **LeskovecKrevl2014** mediante un descargador que cachea localmente los datasets. El parámetro `dataset_name` identifica la red (".ego-Facebook", ".ego-Twitter", etc.); `cache_dir` es la ruta local de caché; `directed` controla si se fuerza un digrafo.

Muchas redes SNAP son no dirigidas (listas de amistades mutuas), pero los flujos de influencia en redes sociales son asimétricos: uno sigue o es influenciado por otro, no necesariamente al revés. Cuando se solicita `directed=True` sobre una red no dirigida, la clase convierte cada arista $\{u, v\}$ en un arco orientado usando una regla probabilística ponderada por grado:

$$P(u \rightarrow v) = \frac{\deg(v)}{\deg(u) + \deg(v)}.$$

La intuición es que los nodos con mayor grado actúan como *influencers*: atraen más seguidores y, por tanto, reciben más arcos entrantes. Por ejemplo, si el nodo u tiene grado 5 y el nodo

v tiene grado 15, entonces

$$P(u \rightarrow v) = \frac{15}{5 + 15} = 0,75,$$

de modo que con probabilidad 0,75 el arco va de u a v (u sigue a v) y solo con probabilidad 0,25 va de v a u . La asignación es independiente arista por arista y el resultado es un digrafo con un único arco por par de nodos.




Figura 8: Red real SNAP ego-Facebook ($n \approx 4000$, no dirigida). Estructura de comunidades visible; alto agrupamiento local ($C = 0,52$) y cola pesada de grado ($k_{\text{máx}} = 1045$).

Multicapa ScaleFree + Watts–Strogatz (MultiLayerGraph). La clase `MultiLayerGraph` es la única que sobrescribe directamente `build()` en lugar de `_build_topology()`, porque gestiona dos topologías independientes con prioridad digital sobre analógica: las aristas de la capa libre de escala no se duplican en la capa Watts–Strogatz. El parámetro `analog` recibe una instancia de `WattsConfig` y `digital` recibe `ScaleFreeConfig` o `SNAPConfig`; si la capa digital es SNAP, `num.nodes` de la capa analógica se ajusta automáticamente al tamaño del dataset descargado.




Figura 9: Red multicapa ScaleFree (digital) + Watts–Strogatz (analógica), $n = 300$. La capa digital (hubs, en rojo) y la analógica (vecindario local, en azul) coexisten sobre los mismos nodos; ambas capas se distinguen por el atributo `layer` de cada arista.

3.2.2. Comparativa de topologías

La Tabla ?? recoge las métricas estructurales clave de las cuatro topologías, calculadas sobre instancias de mayor escala del notebook `grafos_metrics.ipynb` con semilla fija (todas dirigidas tras la anotación `_annotate`).

Tabla 4: Comparativa de métricas estructurales por topología. n : nodos; $\bar{k}_{\text{in}}$: grado entrada medio; $k_{\text{in}}^{\text{máx}}$: grado entrada máximo; C : transitividad; ℓ : camino medio; d : diámetro; r : asortatividad de grado.

Topología	n	$\bar{k}_{\text{in}}$	$k_{\text{in}}^{\text{máx}}$	C	ℓ	d	r
Erdős–Rényi $\mathcal{G}(n, p=0,005)$	10 000	50,00	77	0,005	2,77	4	-0,001
Watts–Strogatz $k=150, p=0,02$	10 000	150,00	159	0,701	2,87	4	0,000
Libre de escala $\alpha=0,41, \beta=0,54$	10 000	1,87	2 836	0,078	4,32	14	-0,154
SNAP ego-Facebook	4 039	43,69	1 045	0,519	3,63	8	+0,064

Los datos cuantifican las diferencias estructurales entre modelos. La red libre de escala concentra la influencia de forma extrema: un único hub acumula $k_{\text{in}}^{\text{máx}} = 2 836$ arcos frente a 77 del nodo más conectado en Erdős–Rényi del mismo tamaño. Sin embargo, la escasez global de aristas ($\bar{k}_{\text{in}} = 1,87$) provoca que el camino medio ($\ell = 4,32$) y el diámetro ($d = 14$) sean los más altos de las tres topologías sintéticas: la mayoría de los nodos tienen muy pocas conexiones y la información debe atravesar muchos saltos para alcanzar el hub. La asortatividad negativa ($r = -0,154$) confirma que el hub recibe arcos de nodos periféricos de bajo grado. Watts–Strogatz muestra la mayor cohesión local ($C = 0,701$) y la distribución de grado más homogénea ($\bar{k}_{\text{in}} = 150, k_{\text{in}}^{\text{máx}} = 159$, asortatividad nula); el 2 % de recableado sobre una base de alta conectividad reduce el diámetro a $d = 4$, idéntico al de Erdős–Rényi pese a un agrupamiento 140 veces mayor. Erdős–Rényi sirve como control sin estructura: agrupamiento y asortatividad próximos a cero, camino medio mínimo ($\ell = 2,77$), referencia para aislar el efecto de la topología. SNAP combina alto agrupamiento ($C = 0,519$) con asortatividad positiva ($r = +0,064$) y un hub de $k_{\text{in}}^{\text{máx}} = 1 045$, rasgos empíricos de redes sociales humanas reales **Newman2003**.

Diseño de hiperparámetros y realismo. La Tabla ?? iguala el tamaño ($n = 10 000$) para que la comparación estructural sea homogénea, pero conviene advertir que los valores de grado medio elegidos —en particular el de Watts–Strogatz— no son los que reproducirían una red social real, sino los que hacen visible el contraste entre modelos. El principio empírico fundamental es que el grado medio de las redes sociales humanas *no escala con el número de nodos*: permanece aproximadamente constante por el límite cognitivo de Dunbar **Dunbar1992**, de modo que las redes grandes son cada vez más dispersas. Un grado medio de $\bar{k} = 150$ sobre $n = 10 000$ implica que cada individuo mantiene lazos estables con el 1,5 % de toda la población, cifra inverosímil: el techo de Dunbar (~ 150 relaciones) es la capacidad total a lo largo de la vida, mientras que los lazos de influencia activos rondan la decena. El control Erdős–Rényi debería derivar su probabilidad de arista del grado objetivo, $p = \bar{k}/(n - 1) \approx 10^{-3}$, en lugar de un p fijo que infla el grado al crecer la red. La topología libre de escala, en cambio, se autocalibra: su mecanismo de adición genera de forma natural un grado medio bajo ($\bar{k} = 1,87$) y hubs emergentes, por lo que es la única que produce densidades realistas sin ajuste manual; el dataset empírico SNAP ($\bar{k}_{\text{in}} = 43,69$ sobre $n = 4 039$)

ofrece el anclaje de referencia sobre el orden de magnitud esperable.

La Tabla ?? recoge únicamente las métricas más representativas para la discusión. El conjunto completo de métricas estructurales de cada topología (Erdős–Rényi, Watts–Strogatz, libre de escala y SNAP) —incluyendo densidad, componentes conexas, reciprocidad, centralidades de intermediación y *PageRank*, y exponentes de la ley de potencias— se adjunta en forma de tablas en el Anexo ??, calculadas con el notebook `grafos_metricas.ipynb`.

3.2.3. Agentes: jerarquía de implementación

El *framework* de simulación multiagente empleado es **Mesa 3 Mesa3**. Frente a alternativas como NetLogo (DSL propietario) o Repast y JADE (ecosistema Java), Mesa implementa directamente en Python el ciclo de vida de los agentes mediante `AgentSet` y `DataCollector`, con un coste de integración mínimo sobre el resto del proyecto. La versión 3 unifica el *scheduling* en un único objeto `AgentSet`, eliminando la necesidad del activador separado de versiones anteriores, y permite activar agentes de forma aleatoria o determinista con una sola llamada. Esta integración nativa con Python facilita la inspección directa del estado de los agentes durante la simulación y la recogida de trazas sin capas adicionales de serialización.

El módulo `src/agents/` organiza todos los modelos de comportamiento bajo la clase abstracta `BaseAgent`, que hereda a su vez de `mesa.Agent`. Esta doble herencia garantiza que todo agente queda automáticamente registrado en el planificador de Mesa (`AgentSet`) al llamar a `super().__init__(model)`, y que posee un `unique_id` autoincremental y una referencia al modelo (`self.model`). El único atributo añadido por `BaseAgent` es `node_id`: el identificador del nodo del grafo donde vive el agente. El método `step()` es abstracto y debe ser implementado por cada subclase.

Se han implementado y evaluado dos subclases concretas: el agente estocástico y el agente resistente. El agente cognitivo-emocional (bayesiano) está diseñado y parcialmente codificado (`src/agents/bayesian.py`), pero no se ha ejecutado experimentalmente; se reserva como línea de trabajo futuro.

Agente estocástico (`StochasticAgent`). Control nulo sin estado cognitivo interno. Cada paso ejecuta dos fases independientes: (i) **reenvío**: si el `inbox` contiene mensajes, con probabilidad `trace_continue_probability` reenvía el último mensaje recibido a un subconjunto aleatorio de vecinos (tamaño $\in [1, |\text{vecinos}|]$); (ii) **creación**: con probabilidad `fire_probability` emite un mensaje de ruido neutro hacia otro subconjunto aleatorio.

Parámetros de instancia:

- `fire_probability` ($p_{\text{fire}} \in [0, 1]$): probabilidad de emitir ruido neutro por paso.
- `trace_continue_probability` ($p_{\text{fwd}} \in [0, 1]$): probabilidad de reenviar el último mensaje del `inbox`.

Ambas probabilidades son independientes: el agente puede reenviar y generar ruido simultáneamente. Al eliminar toda psicología, este modelo aísla la contribución pura de la topología del

grafo y del azar en la difusión; cualquier diferencia observable respecto al agente resistente debe atribuirse a los mecanismos cognitivos añadidos en este último.

Agente resistente (ResistantAgent). Modelo de umbral lineal con estado cognitivo interno compuesto por **conviction** ($c_i \in [0, 1]$) y **theta** ($\theta_i \in [0, 1]$). Cada paso ejecuta tres fases en orden:

1. **Observación:** consume el inbox y, por cada mensaje de la narrativa ($v \leq v_{thr}$), actualiza la convicción según la ecuación (3.4). Si $c_i \geq \theta_i$, registra la adopción (**adopted=True**, **adopted_at=step**, llama a **DataCollector**).
2. **Re-emisión espontánea:** si el agente está adoptado (**adopted=True**) y posee una narrativa guardada (**_last_narrative**), la reenvía con probabilidad **forward_probability** a un subconjunto aleatorio de vecinos, prolongando el periodo infeccioso más allá del paso de adopción.
3. **Ruido ambiental:** con probabilidad **fire_probability** emite un mensaje neutro (igual que el agente estocástico).

Parámetros de instancia (configurados en **NarrativeConfig**):

- **theta** ($\theta_i \in [0, 1]$): umbral de adopción, muestreado de la distribución bimodal que modela dos subpoblaciones diferenciadas:

$$\theta_i \sim \begin{cases} \text{clip}(\mathcal{N}(\mu_s, \sigma^2), 0, 1) & \text{con probabilidad } p_s, \\ \text{clip}(\mathcal{N}(\mu_r, \sigma^2), 0, 1) & \text{con probabilidad } 1 - p_s, \end{cases} \quad (3.7)$$

donde $\mu_s < \mu_r$. Controlado por **susceptible_fraction** (p_s), **theta_susceptible_mu** ($\mu_s = 0,30$), **theta_resistant_mu** ($\mu_r = 0,70$) y **theta_sigma** ($\sigma = 0,10$).

- **gamma** ($\gamma \in [0, 1]$): ganancia de persuasión por exposición.
- **forward_probability** ($f \in [0, 1]$): probabilidad de re-emitar la narrativa en cada paso si adoptado.
- **fire_probability** ($p_{fire} \in [0, 1]$): probabilidad de emitir ruido neutro.
- **narrative_veracity_threshold** ($v_{thr} \in [0, 1]$): umbral de veracidad para clasificar un mensaje como narrativa.

La tabla ?? resume las propiedades de los dos modelos implementados.

Tabla 5: Comparativa de los dos modelos de agente implementados y evaluados.

Clase	Estado interno	Regla de adopción	Parámetros propios
StochasticAgent	Ninguno	No adopta: reenvía ciegamente	fire_probability, trace_continue_probability
ResistantAgent	conviction, theta, adopted	$c_i \geq \theta_i$ (umbral lineal)	gamma, forward_probability, theta_*, susceptible_fraction, narrative_veracity_threshold

3.3. Simulación

3.3.1. Estructura del simulador

El simulador está desarrollado íntegramente en Python 3.13 **PythonLang**, apoyándose en tres dependencias principales. El *framework* de modelado basado en agentes **mesa 3.x Mesa3** aporta el planificador de pasos discretos, la clase base **Agent** y el **AgentSet**, que permiten actuar colectivamente subconjuntos de agentes sin bucles explícitos. La librería **networkx NetworkX2008** proporciona las estructuras de grafo y los algoritmos estándar (grado, betweenness, componentes conexas, carga de redes SNAP). La combinación resulta natural: **mesa** gestiona la lógica de agentes y la recogida de trazas, mientras **networkx** actúa como sustrato topológico intercambiable.

La arquitectura del código está organizada en cinco módulos cohesivos:

- **graphs/**: jerarquía de topologías (**BaseGraph** y subclases); módulo **trust.py** con las funciones de confianza por capa.
- **agents/**: jerarquía de modelos de comportamiento (**BaseAgent** → **StochasticAgent**, **ResistantAgent**).
- **simulation/**: modelo Mesa **NetworkModel**, **DataCollector** (registra cada adopción e interacción), y la clase **Simulation** que orquesta el pipeline.
- **visualization/**: métricas de grafo, gráficas de análisis y *replay* animado de trazas.
- **experiments/**: barridos de hiperparámetros con ejecución paralela (**ProcessPoolExecutor**).

El punto de extensión central es la *agent_factory*: **NetworkModel** recibe una función que construye el agente de cada nodo, de modo que cambiar el modelo de comportamiento no requiere modificar la lógica de simulación.

El **pipeline de una simulación** sigue la secuencia: **build_graph** construye el grafo y asigna confianzas por arista → **NetworkModel** instancia un agente por nodo y configura el **DataCollector** → **inject_narrative** siembra la narrativa entregando mensajes directamente a los inboxes de los nodos seleccionados → bucle de pasos discretos con dos sub-fases por

paso: **TX** (cada agente procesa su inbox y coloca mensajes en el buzón de salida) y **RX** (los mensajes se entregan a los vecinos según el grafo) $\rightarrow$ al finalizar, el **DataCollector** exporta trazas a CSV para análisis en notebook.

La **reproducibilidad** está garantizada por una única semilla entera que controla tres fuentes de aleatoriedad: la generación del grafo, el muestreo de los umbrales θ_i de cada agente y la dinámica estocástica durante la simulación. Con semilla fija, cada corrida es completamente determinista; las réplicas Monte Carlo se obtienen variando únicamente esa semilla. Toda interacción queda registrada con un **trace_id** y un **parent_message_id**, lo que permite reconstruir el árbol de propagación de cualquier narrativa sin necesidad de repetir la simulación.

3.3.2. Experimento ejecutado: barrido OFAT

El experimento diseñado y ejecutado aplica la estrategia *one-factor-at-a-time* (OFAT) sobre el agente resistente en dos topologías. Se define formalmente así: sea $G = (V, E)$ una red con $|V| = N$ nodos. En $t = 0$ se inyecta una narrativa a través de un conjunto de semillas $S \subset V$, $|S| = k$, que quedan con convicción unitaria. El resto de la población parte de $c_i(0) = 0$. Se monitoriza $A(t) = \{i \in V \setminus S : c_i(t) \geq \theta_i\}$ a lo largo del tiempo y se cuantifica la resistencia cognitiva de la población.

Métricas. La *tasa de ataque* $a = |A(T)|/(N-k)$ mide la fracción de no-semillas convertidas al final de la simulación; la *resiliencia* $R = 1 - a$. La *entropía cognitiva* (en bits):

$$H = -[a \log_2 a + (1 - a) \log_2 (1 - a)], \quad (3.8)$$

alcanza su máximo ($H = 1$) cuando la población está dividida en partes iguales y tiende a cero cuando el consenso colapsa, reflejando la pérdida de pluralidad cognitiva **PolytechniqueCNA2026**. La *resistencia individual* del agente i :

$$R_i = \begin{cases} 1 & \text{si el agente no adopta nunca,} \\ 1 - \frac{1}{d_i} & \text{si adopta tras } d_i \text{ exposiciones,} \end{cases} \quad (3.9)$$

donde d_i es la dosis acumulada en el momento de conversión. El *tiempo de penetración* t_{50} es el paso en que se ha convertido la mitad de los agentes que acabarán convirtiéndose.

Hiperparámetros de referencia. Los parámetros del experimento se dividen en dos grupos. Los **hiperparámetros fijos** (Tabla ??) definen el escenario de referencia y no varían en ningún experimento: tamaño de la población, horizonte temporal, distribución bimodal de umbrales y parámetros generativos de cada topología. Su función es aislar el efecto de la narrativa; modificarlos cambiaría el sistema simulado en lugar de la campaña informativa. Los **hiperparámetros barridos** (Tabla ??) son las palancas controlables por el atacante —ganancia de persuasión γ , probabilidad de reenvío f , estrategia y número de semillas k ,

fanout inicial ρ — y dos moduladores de composición y contenido de la narrativa (p_s, λ). Son las variables cuya sensibilidad sobre la resiliencia es el objeto del estudio.

Tabla 6: Hiperparámetros fijos del experimento.

Hiperparámetro	Valor	Justificación	Fuente
N / réplicas MC	10 000 / 50	Equilibrio coste-realismo; ensemble estadístico	—
Días / pasos	3 / 15 paso/día	$T = 45$ pasos equivale a 3 días de actividad	—
μ_s, μ_r, σ	0,30 / 0,70 / 0,10	Dos subpoblaciones; heterogeneidad gobierna cascadas	Granovetter1978, Watts2002
Umbral de veracidad v_{thr}	0,30	Define la narrativa de desinformación rastreada	Vosoughi2018
Libre de escala $\alpha, \beta, \gamma_{BA}, \delta_{in}$	0,41/0,54/0,05/0,02	Produce $\hat{\gamma} \in [2, 3]$ típico de redes digitales	Bollobas2003
Mundo pequeño k, p_{wire}	6 / 0,10	Alto agrupamiento local y diámetro corto; capa analógica. $k=6$ en lugar de valores mayores (véase tabla comparativa, Secc. ??) por eficiencia computacional: $k=150$ sobre $N=10\,000$ nodos implica que cada individuo conoce al 1,5 % de la población, densidad inverosímil que inflaría artificialmente la difusión.	WattsStrogatz1998, Dunbar1992

Diseño OFAT. Se parte del *baseline* de la Tabla ?? y se varía un único factor por experimento sobre las dos topologías. Cada celda experimental se repite con 50 semillas pseudo-aleatorias distintas; cada semilla regenera de forma independiente el grafo, los umbrales θ_i y la trayectoria dinámica. Los resultados se reportan como media $\pm$ desviación estándar sobre las réplicas. El barrido cubre siete factores de la narrativa, produciendo $2 \times 20 \times 50 = 2\,000$ corridas totales, ejecutadas en paralelo sobre múltiples núcleos.

Tabla 7: Hiperparámetros barridos: valor *baseline* (en negrita) y niveles del barrido OFAT con las métricas recogidas en cada celda.

Factor	Símbolo	Baseline	Niveles	Métricas
Ganancia persuasión	γ	0,50	0,25; 0,50; 0,75	$a, R, H, \bar{R}_i, t_{50}$
Estrategia semilla	—	hubs	<i>hubs</i> ; aleatorio	$a, R, H, \bar{R}_i, t_{50}$
Fanout inicial	ρ	0,4	0,2; 0,4; 0,6	$a, R, H, \bar{R}_i, t_{50}$
Número de semillas	k	0,5 %	0,1 %; 0,5 %; 1 %	$a, R, H, \bar{R}_i, t_{50}$
Prob. reenvío	f	0,25	0,10; 0,25; 0,40	$a, R, H, \bar{R}_i, t_{50}$
Fracc. susceptible	p_s	0,50	0,25; 0,50; 0,75	$a, R, H, \bar{R}_i, t_{50}$
Carga emocional	λ	0,60	0,40; 0,60; 0,80	$a, R, H, \bar{R}_i, t_{50}$

Capítulo 4 Resultados

El barrido OFAT descrito en la Secc. ?? produce 2 000 corridas. Cada celda experimental agrega 50 réplicas Monte Carlo, reportadas como media $\pm$ desviación estándar. Todos los resultados se expresan preferentemente en términos de *resiliencia* $R = 1 - a$ (fracción de la población no convertida); cuando conviene razonar sobre la magnitud del ataque se emplea directamente la tasa de ataque a . El escenario de referencia (*baseline*) alcanza $R = 0,78 \pm 0,02$ en la red libre de escala y $R = 0,94 \pm 0,01$ en la de mundo pequeño, valor que sirve de ancla para interpretar el efecto marginal de cada palanca.

4.1. Visión global: resiliencia por factor y topología

La Figura ?? resume el barrido completo: una curva marginal de resiliencia por factor, nivel y topología, con banda de ± 1 desviación estándar sobre las 50 réplicas. Tres regularidades emergen de forma transversal.




Figura 10: Curvas marginales de resiliencia ($R = 1 - a$) por factor y nivel, con banda de $\pm 1 \sigma$ sobre 50 réplicas Monte Carlo. Rojo: libre de escala; azul: mundo pequeño. La línea punteada marca $R = 0,5$.

La topología domina sobre cualquier palanca. La red de mundo pequeño es sistemáticamente más resiliente que la libre de escala en *todas* las celdas del barrido: su curva azul se mantiene siempre por encima de la roja, con una brecha típica de 0,15 puntos de resiliencia. La homogeneidad de grado de la capa analógica priva al atacante de los amplificadores que sí existen en la capa digital, de modo que la misma narrativa convierte a entre dos y tres veces menos población sobre mundo pequeño.

Todos los factores son monótonos. Aumentar la ganancia de persuasión γ , la probabilidad de reenvío f , el número de semillas k , la fracción susceptible p_s o la carga emocional λ reduce la resiliencia de manera monótona en ambas topologías; ningún factor presenta inversiones de signo ni óptimos internos. Esto valida el diseño OFAT: el efecto de cada palanca es interpretable de forma aislada y no se observan no-linealidades que exijan un diseño factorial completo.

La varianza inter-réplica es baja. Las bandas son estrechas ($\sigma \in [0,01, 0,03]$ en casi todas las celdas), lo que indica que las 50 réplicas estiman la resiliencia media con error reducido y que el sistema no exhibe bimodalidad cascada/no-cascada en el rango de parámetros explorado. La excepción es la siembra aleatoria sobre la red libre de escala, cuya mayor dispersión se discute en la Secc. ??.

4.2. Factores de mayor impacto: ganancia de persuasión y probabilidad de reenvío

Las dos palancas que más erosionan la resiliencia son intrínsecas al contenido y a la dinámica de difusión, no a la estructura. La **ganancia de persuasión** γ es el factor más determinante de todo el barrido: al pasar de $\gamma = 0,25$ a $\gamma = 0,75$ la resiliencia cae de 0,90 a

0,69 en la red libre de escala (un rango de 0,21 puntos) y de 0,99 a 0,83 en mundo pequeño (rango 0,16). La **probabilidad de reenvío** f es la segunda palanca: triplicar f de 0,05 a 0,15 reduce la resiliencia de 0,88 a 0,71 (libre de escala) y de 0,98 a 0,87 (mundo pequeño). Ambos resultados confirman la intuición de la guerra cognitiva: lo que controla el alcance de una campaña no es tanto el dispositivo inicial de siembra como la capacidad del mensaje para convencer (γ) y para reproducirse a través de la propia población (f).




Figura 11: Curva de adopción temporal (creyentes acumulados, media $\pm 1\sigma$) para los tres niveles de γ . Izquierda: libre de escala; derecha: mundo pequeño. Un γ mayor no solo eleva la altura final de la cascada, sino que adelanta su arranque.

La Figura ?? muestra que el efecto de γ es doble: además de elevar la altura final de la cascada, adelanta su pendiente de crecimiento. Sobre la red libre de escala las tres curvas saturan pronto —antes del paso 20—, mientras que sobre mundo pequeño el crecimiento es más gradual y prolongado, anticipando el contraste de velocidad analizado en la Secc. ??.

4.3. Vulnerabilidad estructural: siembra en hubs frente a aleatoria

El factor `seed_strategy` aísla el papel de la estructura: compara sembrar la narrativa en los nodos de mayor grado (*hubs*) frente a nodos elegidos al azar, manteniendo idéntico el número de semillas. La brecha entre ambas estrategias es la medida directa de la *vulnerabilidad estructural* de cada topología.




Figura 12: Tasa de ataque (media $\pm 1\sigma$) según la estrategia de siembra. La brecha hubs–aleatorio es enorme en la red libre de escala (0,22 frente a 0,02) y prácticamente nula en mundo pequeño.

El resultado es contundente (Figura ??). Sobre la red **libre de escala**, sembrar en hubs eleva la tasa de ataque a $a = 0,22$, frente a $a = 0,015$ con siembra aleatoria: dirigir el mismo presupuesto de semillas a los hubs multiplica por más de catorce el alcance de la campaña. Sobre la red de **mundo pequeño**, en cambio, la diferencia es marginal ($a = 0,06$ con hubs frente a $a = 0,05$ aleatorio), porque su grado casi homogéneo carece de nodos que concentren audiencia. La conclusión metodológica es nítida: *la vulnerabilidad de la red libre de escala es, en lo esencial, el fenómeno de los hubs*; sin la posibilidad de identificarlos y atacarlos, su ventaja para el atacante se desvanece. Esto explica además la mayor dispersión observada en la siembra aleatoria sobre libre de escala (Secc. ??): el resultado depende de si el azar acierta o no a incluir algún hub entre las semillas.

4.4. Factores de composición: fracción susceptible y carga emocional

Frente a las palancas dinámicas anteriores, la **fracción susceptible** p_s y la **carga emocional** λ describen la composición de la población y del mensaje. Ambas son palancas de impacto intermedio. Triplicar la fracción susceptible de 0,25 a 0,75 reduce la resiliencia de 0,85 a 0,72 en la red libre de escala (rango 0,13) y de 0,98 a 0,88 en mundo pequeño; duplicar la carga emocional de 0,4 a 0,8 produce un efecto comparable (0,86 $\rightarrow$ 0,72 en libre de escala, rango 0,14).




Figura 13: Curva de adopción temporal según la fracción susceptible p_s . A mayor proporción de agentes con umbral bajo, la cascada arranca antes y alcanza mayor altura, en ambas topologías.

La Figura ?? ilustra el mecanismo: p_s fija qué fracción de la población recibe un umbral θ_i bajo (subpoblación susceptible). Cuantos más agentes de umbral bajo, antes encuentra la narrativa nodos que ceden a la primera exposición, de modo que la cascada arranca antes y llega más alto. El efecto es coherente con el resultado clásico de Granovetter **Granovetter1978**: no es la convicción media de la población lo que gobierna la cascada, sino la cola de individuos fácilmente persuasibles que actúa de mecha.

4.5. Velocidad de propagación: t_{50} y pico de conversiones

Más allá de la magnitud final del ataque, la *velocidad* de penetración distingue cualitativamente a las dos topologías. La Figura ?? agrega, por factor y topología, el tiempo de penetración t_{50} (paso en que se convierte la mitad de los agentes que acabarán convirtiéndose) y el paso del pico de nuevas adopciones t_{peak} .




Figura 14: Distribución de t_{50} (izquierda) y t_{peak} (derecha) por factor y topología. La red libre de escala (rojo) penetra antes y alcanza su pico de conversiones casi de inmediato; la de mundo pequeño (azul) difunde lentamente y culmina cerca del final del horizonte.

El contraste es claro. Sobre la red **libre de escala**, $t_{50} \approx 19,5$ pasos y el pico de nuevas conversiones llega casi de inmediato ($t_{peak} \approx 2$): los hubs detonan una onda de choque tem-

prana que satura su audiencia en los primeros pasos y luego decae. Sobre la red de **mundo pequeño**, $t_{50} \approx 30,6$ pasos y el pico se sitúa cerca del final del horizonte ($t_{\text{peak}} \approx 39$): la difusión es una combustión lenta y sostenida que avanza nodo a nodo sin amplificadores. Esta diferencia tiene una lectura defensiva directa: en la capa digital la ventana de intervención útil es de apenas unos pasos tras la siembra, mientras que en la capa analógica la propagación lenta deja un margen de reacción mucho mayor.

4.6. Síntesis visual: heatmap y envolvente de adopción

La Figura ?? condensa todo el barrido en un mapa de calor de resiliencia (media y desviación típica) por factor y nivel, separado por topología. De un vistazo confirma las conclusiones anteriores: la columna de γ presenta la mayor variación de tonalidad —la palanca de mayor impacto—, la red de mundo pequeño aparece uniformemente más verde —más resiliente— y los paneles de desviación típica son uniformemente claros, lo que ratifica la baja varianza inter-réplica y la estabilidad de las estimaciones.




Figura 15: Mapa de calor de resiliencia por factor y nivel: media (izquierda, verde = más resiliente) y desviación típica (derecha) sobre las 50 réplicas, para cada topología. La desviación típica uniformemente baja confirma la estabilidad de las estimaciones.

La Figura ?? agrega todas las corridas con siembra en hubs en una envolvente de adopción por topología, donde la densidad de tonalidad indica la concentración de réplicas. Reúne en una sola imagen los dos regímenes dinámicos descritos: la envolvente de la red libre de escala asciende abruptamente y satura pronto, mientras que la de mundo pequeño crece de forma sostenida sin llegar a estabilizarse dentro del horizonte de simulación.




Figura 16: Envolverte de adopción de todas las corridas con siembra en hubs: media (línea sólida), bandas de percentiles (tonalidad creciente hacia el centro) y rango mín-máx (discontinua). La red libre de escala satura pronto; la de mundo pequeño sigue ascendiendo.

4.7. Síntesis: ranking de factores

Ordenando los factores por su impacto marginal sobre la resiliencia —el rango entre el nivel más y menos favorable— se obtiene una jerarquía que depende de la topología (Tabla ??).

Tabla 8: Ranking de factores por impacto marginal sobre la resiliencia (rango entre niveles extremos del barrido), por topología.

#	Libre de escala		Mundo pequeño	
	Factor	ΔR	Factor	ΔR
1	Ganancia γ	0,21	Ganancia γ	0,16
2	Estrategia de siembra	0,20	Prob. reenvío f	0,12
3	Prob. reenvío f	0,17	Núm. semillas k	0,10
4	Carga emocional λ	0,14	Carga emocional λ	0,10
5	Frac. susceptible p_s	0,13	Frac. susceptible p_s	0,10
6	Núm. semillas k	0,12	Estrategia de siembra	0,01
7	Fanout ρ	0,03	Fanout ρ	0,01

Tres conclusiones cierran el análisis. Primero, la **ganancia de persuasión γ** es la **palanca más potente en ambas topologías**: la calidad persuasiva del mensaje pesa más que cualquier consideración estructural o de volumen de siembra. Segundo, la **estrategia de siembra es el factor más dependiente de la estructura**: ocupa el segundo lugar en la red libre de escala —donde atacar hubs es decisivo— pero cae al penúltimo en mundo pequeño, donde la ausencia de hubs la vuelve irrelevante. Tercero, el **fanout inicial ρ** es

despreciable en ambas redes ($\Delta R \approx 0,02$): el número de contactos del primer salto apenas condiciona el resultado, porque la propagación posterior, gobernada por γ y f , domina sobre la amplitud del impulso inicial. En conjunto, los resultados dibujan un atacante eficaz que prioriza la calidad persuasiva y la viralidad del mensaje sobre el tamaño del dispositivo de siembra, y que solo obtiene rendimiento de la siembra dirigida cuando la red posee hubs que explotar.

Capítulo 5 Conclusiones y Trabajo Futuro

5.1. Conclusiones

5.2. Trabajo Futuro

Capítulo 6 Bibliografía

Capítulo A Hiperparámetros y resultados extendidos del barrido OFAT

La Tabla ?? recoge los valores completos de tasa de ataque media y desviación estándar para todas las celdas del barrido experimental (7 factores $\times$ niveles $\times$ 2 topologías, 50 réplicas MC cada una, $N = 10\,000$).

Tabla 9: Resultados completos del barrido OFAT. Tasa de ataque media $\pm\sigma$ y resiliencia $R = 1 - a$ para cada celda experimental.

Factor	Nivel	Libre de escala		Mundo pequeño	
		$a \pm \sigma$	R	$a \pm \sigma$	R
γ	0,25	$0,238 \pm 0,017$	0,762	$0,031 \pm 0,003$	0,969
	0,50	$0,412 \pm 0,026$	0,588	$0,130 \pm 0,010$	0,870
	0,75	$0,513 \pm 0,032$	0,487	$0,355 \pm 0,029$	0,645
Semilla	<i>hubs</i>	$0,412 \pm 0,026$	0,588	$0,130 \pm 0,010$	0,870
	<i>random</i>	$0,106 \pm 0,073$	0,894	$0,089 \pm 0,007$	0,911
ρ	0,2	$0,403 \pm 0,031$	0,597	$0,123 \pm 0,010$	0,877
	0,4	$0,412 \pm 0,026$	0,588	$0,130 \pm 0,010$	0,870
	0,6	$0,424 \pm 0,028$	0,576	$0,137 \pm 0,011$	0,863
k	0,1 %	$0,329 \pm 0,031$	0,671	$0,032 \pm 0,006$	0,968
	0,5 %	$0,412 \pm 0,026$	0,588	$0,130 \pm 0,010$	0,870
	1,0 %	$0,447 \pm 0,028$	0,553	$0,230 \pm 0,012$	0,770
f	0,10	$0,218 \pm 0,018$	0,782	$0,026 \pm 0,003$	0,974
	0,25	$0,412 \pm 0,026$	0,588	$0,130 \pm 0,010$	0,870
	0,40	$0,520 \pm 0,029$	0,480	$0,363 \pm 0,023$	0,637
p_s	0,25	$0,340 \pm 0,020$	0,660	$0,058 \pm 0,005$	0,942
	0,50	$0,412 \pm 0,026$	0,588	$0,130 \pm 0,010$	0,870
	0,75	$0,481 \pm 0,030$	0,519	$0,276 \pm 0,018$	0,724
λ	0,4	$0,307 \pm 0,021$	0,693	$0,054 \pm 0,005$	0,946
	0,6	$0,412 \pm 0,026$	0,588	$0,130 \pm 0,010$	0,870
	0,8	$0,485 \pm 0,031$	0,515	$0,260 \pm 0,019$	0,740

Capítulo B Métricas estructurales completas de las redes

La Tabla ?? recoge el conjunto completo de métricas estructurales de las cuatro topologías estudiadas, calculadas con el notebook `grafos_mtricas.ipynb` sobre instancias dirigidas con semilla fija (`seed = 42`). Las topologías sintéticas se generan con $n = 10\,000$ nodos; el dataset empírico SNAP (*ego-Facebook*) tiene $n = 4\,039$. La Tabla ?? del cuerpo principal selecciona un subconjunto de estas métricas para la discusión.

Tabla 10: Métricas estructurales completas por topología. Topologías sintéticas con $n = 10\,000$; SNAP *ego-Facebook* con $n = 4\,039$. Calculadas sobre los grafos dirigidos con `seed = 42`.

Métrica	Erdős–Rényi	Watts–Strogatz	Libre de escala	SNAP
Nodos (n)	10 000	10 000	10 000	4 039
Aristas (m)	500 024	1 500 000	18 689	176 468
Densidad	0,00500	0,01500	0,00019	0,01082
Componentes conexas	1	1	1	1
Tamaño LCC	10 000	10 000	10 000	4 039
Fracción LCC	1,000	1,000	1,000	1,000
Componentes fuertes (SCC)	1	1	9 693	1
Reciprocidad	1,000	1,000	0,005	1,000
Transitividad (C)	0,0050	0,7012	0,0782	0,5192
Camino medio (ℓ)	2,774	2,874	4,321	3,627
Diámetro (d)	4	4	14	8
Asortatividad de grado (r)	-0,001	0,000	-0,154	0,064
Grado entrada medio ($\bar{k}_{in}$)	50,00	150,00	1,87	43,69
Grado entrada máx. ($k_{in}^{máx}$)	77	159	2 836	1 045
Grado salida medio ($\bar{k}_{out}$)	50,00	150,00	1,87	43,69
Grado salida máx. ($k_{out}^{máx}$)	77	159	139	1 045
Intermediación media	1,77e-4	1,87e-4	1,62e-5	6,71e-4
Intermediación máx.	5,22e-4	7,46e-4	0,0373	0,4830
<i>PageRank</i> medio	1,00e-4	1,00e-4	1,00e-4	2,48e-4
<i>PageRank</i> máx.	1,46e-4	1,05e-4	0,0887	7,61e-3
Exponente γ_{in}	1,218	1,175	1,686	1,259
Exponente γ_{out}	1,218	1,175	1,901	1,259